

Customer Shopping Behavior Analysis Report

Table of Contents

Phase 1 — Foundation: Understanding, Preparing and Exploring the Data	3
1. Case Context & Analytical Perspective	3
1.1 Background and data analytics perspective	3
1.2 Position in the data analytics lifecycle	3
1.3 Role of data wrangling and EDA	4
1.4 Visual analytics perspective	5
1.5 Role of visualization at the early stage of the project	6
1.6 What visualization reveals beyond raw tables	6
2. Data Understanding & Data Quality Assessment	7
2.1 Dataset description (raw data)	7
2.2 Data quality issues identified	9
2.3 Why unresolved issues would affect the analysis	9
3. Data Wrangling & Preparation	10
3.1 Cleaning and preparation steps	10
3.2 Handling missing values and outliers	12
3.3 Transformations and derived variables	12
3.4 Resulting dataset (data dictionary after wrangling)	13
4. Exploratory Data Analysis & Exploratory Visualization	14
4.1 Descriptive statistics	14
4.2 Distributions and comparisons	15
4.3 Patterns, trends and relationships	19
4.4 Visualization-related data challenges	21
4.5 Exploratory visualizations in Tableau	22
4.6 Early visualization design: one question, one chart	25
Phase 2 — Depth: Evaluation, Advanced Analysis, Prediction and Communication	28
5. Data Quality Review & Evaluation	28
5.1 Data quality issues identified in Phase 1	28
5.2 Effectiveness of the data wrangling	29
5.3 Evidence from measurable indicators	30
6. Advanced Pattern, Trend & Relationship Analysis	32
6.1 Deeper exploration: segmentation, time-based trends and subgroup comparison	32
6.2 Most influential variables	38
6.3 Why these relationships are meaningful	39
7. Evaluation of Analytical Methods & Metrics	40
7.1 Analytical techniques and models used	40
7.2 Evaluation metrics	41
7.3 Limitations	43

8. Dashboard & Visual Communication Design	43
8.1 Time-series and trend visualization	44
8.2 Composition and proportion visualization	46
8.3 Integrated dashboard design	48
8.4 Storytelling, audience fit and design defense	51
9. Recommendations	54
Recommendation 1 — Strategi Akselerasi Konversi Pelanggan melalui Segmentasi Berbasis Gender	54
Recommendation 2 — Peninjauan Ulang Strategi Diskon sebagai Alat Konversi Subscriber	55

Dataset: Customer Shopping Behavior (3,900 transactions · 18 original variables)

Tools: Python (pandas, scikit-learn, XGBoost, imbalanced-learn), Tableau

Published dashboard (Tableau Public):
<https://public.tableau.com/app/profile/nabila.mukhbata/viz/CustomerShoppingBehaviorAnalysisDashboard/ExecutiveSummary?publish=yes&showOnboarding=true>

This report documents the whole project from raw data to recommendations. It is organised in two phases that follow one analytics lifecycle:

Phase	Goal	Analytics track	Visualization track
Phase 1 — Foundation	Understand, clean and explore the data	Sections 1–4 · notebook 01	Sections 1, 3, 4 · dashboards/phase1_exploratory_views.twbx
Phase 2 — Depth	Evaluate quality, go deeper, predict, communicate, recommend	Sections 5–7, 9 · notebooks 02–04	Section 8 · dashboards/phase2_executive_dashboard.twbx

Phase 1 — Foundation: Understanding, Preparing and Exploring the Data

1. Case Context & Analytical Perspective

1.1 Background and data analytics perspective

Memahami *customer behaviour* merupakan hal yang penting bagi sektor industri retail maupun *e-commerce* untuk mengoptimalkan strategi pemasaran, pengambilan keputusan bisnis dan meningkatkan kepuasan konsumen sehingga loyalitas pelanggan bisa terbentuk. Untuk mewujudkan tujuan tersebut, penting bagi perusahaan untuk mengidentifikasi preferensi produk, pola pembelian pelanggan serta faktor-faktor yang mempengaruhi preferensi mereka ketika berbelanja.

Kasus yang menjadi fokus analisis dalam proyek ini adalah analisis pola perilaku belanja pelanggan dan mengidentifikasi faktor-faktor yang mempengaruhi *purchase amount* berdasarkan kategori produk, karakteristik pelanggan dan penggunaan diskon. Dari perspektif *data analytics*, proses pengolahan data ini dilakukan secara sistematis mulai dari pengumpulan data, *data cleaning* & transformasi data serta proses analisis data untuk menghasilkan *insight* yang memiliki nilai bisnis.

Proyek ini menggunakan 2 pendekatan dalam *data analytics* yaitu ***descriptive analytics*** yang bertujuan untuk mengidentifikasi pola, tren maupun distribusi data dari perilaku belanja pelanggan dan ***diagnostic analytics*** yang bertujuan untuk menemukan hubungan antar variabel dan mencari tahu mengapa pola tertentu muncul dari data *customer shopping behaviour*. Dengan menggunakan kedua pendekatan tersebut memungkinkan perusahaan untuk memahami apa yang terjadi melalui data historis sekaligus memvalidasi mengapa hal tersebut bisa terjadi untuk mengambil keputusan bisnis yang tepat sasaran dan akurat.

1.2 Position in the data analytics lifecycle

CRISP-DM (*Cross Industry Standard Process for Data Mining*) merupakan pendekatan terstruktur yang iteratif untuk memastikan setiap keputusan bisnis diambil berdasarkan fakta yang diperoleh dari data. Proyek ini menggunakan *framework* CRISP-DM yang memandu seluruh tahapan *data analytics lifecycle* mulai dari *business understanding*, *data understanding*, *data preparation*, *modeling*, *evaluation* , hingga *deployment* .

Proyek ini sejalan dengan tahap awal CRISP-DM terutama pada tahap awal yaitu *business understanding*, *data understanding* , dan *data preparation* .

1. Business Understanding

Tahap ini bertujuan untuk mengetahui kebutuhan bisnis dan menentukan tujuan analisis sehingga fokus analisis bisa lebih jelas. Dalam kasus ini perusahaan ingin memahami perilaku belanja pelanggan untuk mengetahui pola pembelian pelanggan, preferensi produk pelanggan dan faktor-faktor yang mempengaruhi keputusan pembelian pelanggan. *Business understanding* mengubah keinginan yang umum seperti “mengetahui perilaku pelanggan” menjadi lebih spesifik seperti “mengidentifikasi faktor-faktor yang mempengaruhi *purchase amount* pelanggan”.

2. Data Understanding

Dalam tahapan ini data dikumpulkan dan dilakukan eksplorasi untuk memahami struktur data, variabel-variabel yang tersedia dalam data serta kualitas data. Kegiatan yang dilakukan dalam tahap ini yakni menganalisis tipe data dan mengidentifikasi potensi masalah dalam kualitas data seperti *missing value* , *duplicate data* , *inconsistency* kategori data, maupun *data outlier*. Dalam proyek ini dilakukan eksplorasi dataset *customer shopping behaviour* dimana ditemukan 3900 baris dan 18 kolom dengan berbagai tipe data (int,string).

3. Data Preparation

Dalam tahap ini dilakukan pembersihan, transformasi dan standarisasi format data agar data siap dianalisis. Tahap ini penting untuk dilakukan karena data yang kotor akan menghasilkan analisis yang tidak akurat. Dalam proyek ini dataset dibersihkan dengan cara : menangani *missing value* , menghapus data duplikat dan menangani *inconsistency* data, *encoding* kategori dalam data, kemudian melakukan transformasi data dengan cara standarisasi. Selain itu, dilakukan juga *feature engineering* dan *data reduction* seperti drop kolom yang kurang relevan dengan tujuan analisis yang ingin dicapai. Tahap *data preparation* bertujuan untuk menghasilkan data yang sudah siap untuk dianalisis dan digunakan pada tahap selanjutnya sehingga hasil analisis nanti akurat.

1.3 Role of data wrangling and EDA

Data Wrangling adalah bagian inti dari tahap *data preparation* dimana terjadi proses mengumpulkan, membersihkan dan standarisasi format agar memastikan kualitas data untuk proses analisis lebih

lanjut. Dalam kasus ini *data wrangling* berperan untuk memastikan dataset *customer shopping behaviour* layak untuk digunakan sebelum dianalisis di tahap selanjutnya sehingga nanti hasil analisis akurat. Proses *data wrangling* mencakup:

1. Mengidentifikasi, menentukan strategi penanganan dan menangani *missing value* .
2. Menghapus data duplikat untuk menghindari hasil analisis yang bias.
3. Memperbaiki inkonsistensi pada data kategorikal, seperti pada kategori ' *Every 3 Months* ' menjadi ' *Quarterly* ' dan ' *Bi-Weekly* ' menjadi ' *Fortnightly* ' karena keduanya sebenarnya memiliki makna yang sama.
4. Melakukan standarisasi format data.
5. Mengurangi jumlah variabel yang tidak relevan dengan tujuan analisis (*drop column*) seperti kolom *customerID*, *Size* dan *Color* .
6. Melakukan *feature engineering* untuk mempermudah analisis seperti penambahan kolom *Age Group* dan *Purchase Frequency Tier*.
7. Mendeteksi dan menangani data outlier agar hasil analisis statistik lebih akurat.

EDA (*Exploratory Data Analysis*) adalah pendekatan yang digunakan dalam eksplorasi data awal untuk menemukan pola dan mendeteksi anomali dengan bantuan ringkasan statistik dan visualisasi. Dalam proyek ini EDA berperan dalam menemukan *insight* awal mengenai pola perilaku belanja pelanggan, mengetahui faktor-faktor yang mempengaruhi maupun anomali dalam data yang bisa menjadi dasar untuk analisis lebih lanjut dengan bantuan visualisasi dan deskriptif statistik. Dalam kasus ini EDA digunakan untuk:

1. Menganalisis pola pembelian pelanggan dengan *bar chart* maupun histogram untuk melihat kategori yang paling sering dibeli, metode pembayaran yang paling populer dan frekuensi pembelian pelanggan.
2. Mengidentifikasi hubungan antar variabel seperti korelasi antara penggunaan diskon dengan jumlah pembelian atau hubungan antara jumlah pembelian sebelumnya dengan frekuensi pembelian.
3. Memahami distribusi data pelanggan seperti distribusi variabel *age*, *review rating* , dan *purchase amount* untuk mengetahui karakteristik umum pelanggan.
4. Mengidentifikasi *outlier* menggunakan visualisasi seperti *boxplot* untuk membantu mendeteksi nilai anomali yang bisa mempengaruhi hasil analisis.

1.4 Visual analytics perspective

Dalam sektor bisnis retail perlu memiliki pemahaman yang mendalam mengenai perilaku konsumen untuk meningkatkan efisiensi operasional dan daya saing bisnis. Oleh karena itu, proyek ini difokuskan untuk menganalisis perilaku belanja konsumen menggunakan *customer behaviour dataset* dalam memahami pola pengeluaran (*purchase amount*) dan faktor-faktor yang mempengaruhinya.

Data Visualisasi adalah proses mengubah data menjadi representasi grafis menggunakan elemen visual seperti grafik, diagram atau plot. Sebelum data digunakan untuk keperluan analisis lanjutan, diperlukan tahap eksplorasi awal untuk memastikan data benar-benar dipahami secara menyeluruh. Pada *data analytics* , kami menggunakan pendekatan analitik visual eksploratif yang dilakukan melalui EDA untuk memperoleh gambaran awal mengenai distribusi data, hubungan antar variabel dan faktor-faktor yang berpotensi mempengaruhi *purchase amount* secara visual.

Dalam proyek data visualisasi, fokus utamanya adalah merepresentasikan data secara visual yang bersih dan memberikan pesan yang jelas. Tahap ini menggunakan perspektif *communicative visualization* dengan mempertimbangkan prinsip persepsi visual manusia dalam pemilihan warna, posisi, panjang dan memungkinkan pola dalam data dapat dikenali dengan cepat dan mudah tanpa beban kognitif yang besar.

Dalam pendekatan *communicative visualization* presentasi data difokuskan ke dalam 3 aspek utama yaitu :

- a. *Comparison* , yang tujuannya mempresentasikan perbedaan perilaku segmen pelanggan berdasarkan karakteristik tertentu.
- b. *Distribution*, yang tujuannya untuk memahami bentuk dan sebaran nilai pembelian pelanggan.
- c. *Correlation*, yang tujuannya mengevaluasi apakah ada hubungan yang signifikan antar variabel dalam data.

Pendekatan tersebut diwujudkan dengan pemilihan alat visualisasi seperti *scatter plot* , *boxplot* , dan *bar chart* yang masing-masing menampilkan data dengan struktur yang berbeda. Selain sebagai alat presentasi, visualisasi dijadikan sebagai sarana untuk “alat bantu berpikir” sehingga analisis dapat menemukan insight yang mungkin tidak terlihat melalui analisis numerik semata.

1.5 Role of visualization at the early stage of the project

Pada tahap awal proyek, data visualisasi memiliki peran yang penting sebagai sarana eksplorasi, pemahaman data dan validasi bukan sebagai media komunikasi akhir sehingga fokus utama dalam tahap ini memastikan bahwa data telah dipahami dengan baik melalui representasi visual yang tepat sebelum digunakan untuk pengambilan keputusan atau penyusunan narasi. Berikut adalah peran data visualisasi:

1. *Understanding Data Shape* Visualisasi digunakan untuk melihat bentuk data secara keseluruhan dan membantu mengidentifikasi pola yang tersembunyi dalam data. Visualisasi bisa digunakan untuk mengetahui apakah data berdistribusi normal atau ada kemiringan yang menunjukkan dominasi kelompok tertentu melalui grafik seperti box plot. Dengan visualisasi, data tersebut diubah menjadi lebih mudah dipahami dibandingkan tabel yang kurang memberikan representasi yang intuitif.

2. Sebagai Alat Identifikasi Potensi Hubungan Melalui *heat map* visualisasi berperan dalam pembuktian apakah ada hubungan linear antara variabel. Nilai-nilai korelasi seperti -0.01 atau 0.01 yang mendekati 0 akan lebih sulit untuk dibandingkan secara mental apabila disajikan dalam bentuk angka, namun dengan *heat map* menjadi mudah diidentifikasi secara cepat dibandingkan harus membandingkan semua nilai angka satu per satu untuk menentukan kuat lemahnya hubungan antar variabel.

3. *Cross-Segment Comparison* Melalui *bar chart* visualisasi memungkinkan kita membandingkan kategori-kategori tertentu secara berdampingan untuk memberikan kepastian visual.

Visualisasi dalam tahap ini juga berperan dalam *diagnostic* (contohnya ketika visualisasi *Previous Purchases* tidak terlihat trend naik pada jumlah belanja yang bisa menjadi sinyal bahwa ada ketidakefisienan program loyalitas saat ini untuk meningkatkan *upselling*). Visualisasi juga berperan menjadi alat untuk membangun intuisi awal sehingga harus memastikan pola yang terlihat murni dari data bukan kesalahan pemilihan grafik.

1.6 What visualization reveals beyond raw tables

Manusia memiliki keterbatasan dalam memproses angka di dalam tabel sehingga visualisasi membantu menjelaskan struktur, variasi dan perbandingan data yang sulit dilihat secara langsung melalui tabel. Dataset perilaku belanja pelanggan hanya menyajikan nilai-nilai tiap individu tanpa menunjukkan pola-pola dalam data sehingga diperlukan visualisasi untuk :

1. Mengungkap Struktur Visualisasi seperti histogram membantu dalam menunjukkan struktur data untuk melihat dominasi pada kategori tertentu dan nilai setiap kategori. Dalam kasus dataset customer behaviour kegunaan visualisasi seperti dengan histogram pada data *purchase amount* dapat terlihat bahwa data terlihat merata dan tidak membentuk bell curve.
2. Mengungkap Variasi Dengan menggunakan grafik seperti boxplot untuk melihat max, min, rentang dan sebaran nilai maka ini bisa membantu untuk mengidentifikasi nilai *outlier* , tingkat variabilitas antar pelanggan dan mengetahui apakah data tersebar merata atau terkonsentrasi. Dalam kasus *customer behavior* , visualisasi bisa menunjukkan variasi yang konsisten (median nilai pembelian stabil) di seluruh kategori. Konsistensi sebaran ini akan sulit diidentifikasi melalui tabel mentah karena boxplot menyajikan perbandingan distribusi secara visual yang lebih intuitif.
3. Mengungkap Perbandingan

Dengan menggunakan alat bantu seperti *bar chart* memungkinkan kita untuk membandingkan performa antar kategori secara lebih efektif dibandingkan membandingkan angka di tabel terutama jika datanya dalam jumlah yang besar. Contohnya dalam kasus *customer behavior* kita bisa membandingkan *spending customer* di setiap kategori dan gender secara bersamaan. Oleh karena itu, visualisasi bisa membantu kita melihat perbedaan kontras secara cepat.

Visualisasi berperan dalam membantu mengubah data dari tabel yang kurang intuitif menjadi visualisasi yang lebih mudah dipahami untuk meringankan beban kognitif. Visualisasi juga memastikan bahwa interpretasi data didasarkan pada pola yang benar-benar ada, bukan hanya asumsi dari angka-angka oleh individual.

2. Data Understanding & Data Quality Assessment

Implementation: `notebooks/01_data_preparation_and_edu.ipynb` — *Data Loading and Data Understanding.*

2.1 Dataset description (raw data)

Dataset yang digunakan untuk kasus ini adalah *Customer Shopping Behaviour Dataset* yang berisi sekitar 3900 baris data transaksi pelanggan dengan 18 variabel yang menggambarkan perilaku pembelian pelanggan pada suatu platform e-commerce. Struktur dataset berupa data tabular yang terdiri dari baris dan kolom dimana setiap baris merepresentasikan satu transaksi unik. Berikut adalah *key variables* dan deskripsinya :

Variabel	Tipe Data	Deskripsi	Values
Customer ID	Numerical (INT)	ID unik setiap pelanggan	1-3900
Age	Numerical (INT)	Usia pelanggan	18 - 70 Tahun
Gender	Categorical (String)	Jenis kelamin pelanggan	Male, Female
Item Purchased	Categorical (String)	Nama produk yang dibeli	Blouse, Sweater, Jeans, Sandals, Sneakers, Shirt, Shorts, Coat, Handbag,

Variabel	Tipe Data	Deskripsi	Values
			Shoes, Dress, Skirt, Sunglasses, Pants, Jacket, Hoodie, Jewelry, T-shirt, Scarf, Hat, Socks, Backpack, Belt, Boots, Gloves
Category	Categorical (String)	Kategori produk	Clothing, Footwear, Outerwear, Accessories
Purchase Amount (USD)	Numerical (INT)	Jumlah pembelian	20 -100 USD
Location	Categorical(String)	Lokasi pelanggan	Kentucky, Maine, Massachusetts, Rhode Island, Oregon, Wyoming, Montana, Louisiana, West Virginia, Missouri, Arkansas, Hawaii, Delaware, New Hampshire, New York, Alabama, Mississippi, North Carolina, California, Oklahoma, Florida, Texas, Nevada, Kansas, Colorado, North Dakota, Illinois, Indiana, Arizona, Alaska, Tennessee, Ohio, New Jersey, Maryland, Vermont, New Mexico, South Carolina, Idaho, Pennsylvania, Connecticut, Utah, Virginia, Georgia, Nebraska, Iowa, South Dakota, Minnesota, Washington, Wisconsin, Michigan

Size	Categorical(C H A R)	Ukuran produk	S, M, L, XL
Color	Categorical(String)	Warna produk	Gray, Maroon, Turquoise, White, Charcoal, Silver, Pink, Purple, Olive, Gold, Violet, Teal, Lavender, Black, Green, Peach, Red, Cyan, Brown, Beige, Orange, Indigo, Yellow, Magenta, Blue
Season	Categorical(String)	Musim pembelian	Winter, Spring, Summer, Fall
Review Rating	FLOAT	Rating produk	2.5 - 5.0
Subscription Status	BOOLEAN	Status langganan pelanggan	Yes, No
Shipping Type	Categorical(String)	Metode Pengiriman	Express, Free Shipping, Next Day Air, Standard,

			2-Day Shipping, Store Pickup
Discount Applied	BOOLEAN	Apakah diskon digunakan?	Yes, No
Promo Code Used	BOOLEAN	Apakah kode promo digunakan?	Yes, No
Previous Purchases	INT	Jumlah pembelian sebelumnya	1-50
Payment Method	Categorical(String)	Metode pembayaran	Venmo, Cash, Credit Card, PayPal, Bank Transfer, Debit Card
Frequency of Purchases	Categorical(String)	Frekuensi pembelian	Fortnightly, Weekly, Annually, Quarterly, Bi-Weekly, Monthly, Every 3 Months

2.2 Data quality issues identified

1. Missing Value

Hasil pemeriksaan menunjukkan bahwa dataset tidak memiliki *missing values* sama sekali sehingga setiap data tercatat secara lengkap dimana ini adalah kondisi ideal dan tidak memerlukan penanganan khusus seperti penghapusan *row* atau mengisi dengan nilai rata-rata.

2. Outlier

Proses deteksi *outlier* yang dilakukan pada variabel numerik seperti *Age*, *Purchase Amount (USD)*, *Review Rating*, dan *Previous Purchases* menggunakan metode *Interquartile Range (IQR)* menunjukkan bahwa seluruh nilai masih berada dalam rentang batas statistik yang wajar (tidak berada di bawah Q1 maupun di atas Q3). Selain itu, untuk verifikasi tambahan dilakukan juga deteksi *outlier* dengan menggunakan Z-Score dengan *threshold* > 3 yang juga menunjukkan bahwa tidak ditemukan data *outlier*. Temuan ini menunjukkan bahwa dataset yang digunakan berdistribusi relatif stabil dan tidak memiliki nilai ekstrim yang bisa mempengaruhi hasil analisis.

3. Inconsistencies

Dalam kolom *Frequency of Purchases* terdapat kategori “*Quarterly*” yang memiliki makna yang sama dengan “*Every 3 Months*”, dan “*bi-weekly*” memiliki makna yang sama dengan “*Fortnightly*”. Selain itu, beberapa kolom seperti *Subscription Status*, *Discount Applied*, dan *Promo Code Used* masih menggunakan format *Yes* atau *No* sehingga perlu di standarisasi menjadi 1 dan 0 agar lebih mudah digunakan dalam proses analisis data.

4. Duplicates

Pemeriksaan terhadap *data duplicate* penting untuk dilakukan agar bisa menghindari hasil yang bias terhadap analisis yang menggunakan perhitungan. Hasil pemeriksaan terhadap *data duplicate* menunjukkan tidak ditemukan *duplicate records* sehingga setiap baris *record* merepresentasikan transaksi yang unik.

2.3 Why unresolved issues would affect the analysis

Pemeriksaan kualitas data penting dilakukan karena masalah pada data dapat mempengaruhi hasil analisis. Berdasarkan pengecekan pada dataset, tidak ditemukan *missing value* maupun data duplikat.

Artinya seluruh data pada dataset ini lengkap dan setiap baris mewakili transaksi yang berbeda, sehingga data bisa langsung digunakan untuk proses analisis tanpa perlu menghapus data yang sama atau menangani nilai kosong.

Walaupun tidak terdapat *missing value* , penting untuk memahami dampaknya jika terdapat *missing value* . Jika variabel penting seperti *Age* atau *Purchase Amount (USD)* memiliki nilai yang hilang, maka perhitungan seperti rata-rata atau distribusi data bisa menjadi kurang akurat karena tidak semua data ikut dihitung. Selain itu, data duplikat juga dapat mempengaruhi hasil analisis. Jika satu transaksi tercatat lebih dari sekali, jumlah transaksi akan terlihat lebih banyak dari kondisi sebenarnya dan bisa membuat perhitungan seperti total pembelian atau rata-rata transaksi menjadi tidak tepat.

Pada dataset terdapat inkonsistensi pada data kategorikal di kolom Frequency of Purchases seperti “Quarterly” dan “Every 3 Months” serta “Bi-weekly” dengan “Fortnightly” yang sebenarnya memiliki arti sama. Jika tidak diseragamkan, keduanya akan dianggap sebagai kategori yang berbeda sehingga hasil analisis frekuensi pembelian bisa kurang akurat.

Selain itu, beberapa kolom seperti *Subscription Status* , *Discount Applied* , dan *Promo Code Used* masih menggunakan format *Yes* dan *No* . Nilai ini dapat diubah menjadi format numerik seperti 1 dan 0 agar lebih mudah digunakan dalam proses analisis.

Dalam data juga diperiksa kemungkinan adanya *outlier* pada variabel numerik seperti *Purchase Amount (USD)* , karena nilai yang terlalu jauh dari data lainnya dapat mempengaruhi hasil perhitungan seperti rata-rata dan membuat analisis kurang merepresentasikan kondisi sebagian besar pelanggan. Oleh karena itu semua aspek yang mempengaruhi kualitas data perlu untuk ditangani dengan baik agar tidak mempengaruhi akurasi analisis dan *insight* yang dihasilkan.

3. Data Wrangling & Preparation

Implementation: notebook 01 — Data Cleaning, Data Validation, Feature Engineering

3.1 Cleaning and preparation steps

Proses *data wrangling* dilakukan agar memastikan kualitas untuk proses analisis dan bebas dari ketidak konsistenan. Langkah-langkahnya meliputi:

1. Data Collection (*Data Loading* dan *Initial Inspection*)

Dataset *shopping_behavior_updated.csv* dimuat ke dalam Google Colab kemudian *file csv* tersebut dibaca dari *environment* Colab dan dimasukkan ke dalam *variable data frame* (*df*) menggunakan *library pandas*. Kemudian pemeriksaan awal dilakukan dengan :

- *df.head()* untuk melihat *preview* data agar memastikan data berhasil termuat dengan baik.
- *df.info()* untuk memahami tipe data dan kelengkapan.
- *df.describe()* untuk melihat statistik dasar seperti *count*, *mean*, *std*, *min*, *max*, *median*, *Q1* dan *Q3*
- *df.isnull().sum()* untuk melihat total nilai null dalam data
- *df.duplicated().sum()* untuk melihat total duplicated records
- Dari hasil pemeriksaan tersebut ditemukan :

- a. Total data sebanyak 3900 *row*
- b. Total fitur sebanyak 18 kolom
- c. Tipe data terdiri dari:
 - i. Numerik sebanyak 5 kolom
 - ii. Kategorikal sebanyak 13 kolom
- d. Tidak ditemukan *missing value*, *outlier data* maupun *duplicate data*

2. Data Cleaning

a. Penanganan Inkonsistensi Berdasarkan pengecekan *unique values* tiap kolom kategorikal ditemukan adanya kategori yang memiliki makna sama pada kolom *frequency of purchases* sehingga harus distandarisasi.

b. Feature Selection / Data Reduction

Beberapa kolom seperti *CustomerID*, *Color* dan *Size* dihapus karena kurang relevan untuk dianalisis dan tidak memberikan nilai analitis yang signifikan. *CustomerID* dihapus karena hanya sebagai *identifier* sedangkan *color* dan *size* dihapus karena lebih merepresentasikan ke karakteristik produk dibanding perilaku belanja pelanggan yang menjadi fokus utama analisis sehingga kedua variabel ini tidak memberikan kontribusi secara langsung untuk memahami tren belanja.

c. Encoding

Variabel kategorik biner (yang mengandung nilai *yes/no*) ditransformasi menjadi *numeric format* (*yes* =1 dan *no* =0) agar bisa dianalisis secara kuantitatif.

3. Feature Engineering

Variabel baru seperti *Age Group* (*Young Adult*, *Adult*, *Senior*) dan *Purchase Frequency Tier* (*High*, *Medium*, *Low*) dibuat untuk mempermudah segmentasi *customer* dan mendukung analisis yang lebih dalam.

4. Data Validation

Validasi data dilakukan untuk memastikan kembali bahwa seluruh nilai dalam dataset berada dalam rentang yang logis serta menjamin keandalan data yang dilakukan dengan beberapa aturan logika seperti

- Age harus berada dalam rentang usia wajar (≥ 18 tahun)
- Purchase Amount (USD) harus bernilai positif (> 0)
- Review Rating berada dalam skala yang valid (1–5)
- Previous Purchases tidak boleh bernilai negatif

Hasil dari validasi tersebut menunjukkan bahwa semua data memenuhi aturan logis tersebut. Selain itu dilakukan pengecekan *missing value* dan *duplicate row* serta deteksi *outlier Z-Score* kembali untuk validasi.

5. Data Export

Dataset yang sudah bersih disimpan dalam format CSV menggunakan `df.to_csv()` sehingga dapat digunakan untuk tahap analisis lebih lanjut.

3.2 Handling missing values and outliers

Missing value dan *outlier handling* merupakan bagian dari proses *data cleaning*. Pada tahap awal dilakukan *data quality checking* terlebih dahulu untuk mengetahui keadaan dataset sebelum memutuskan teknik yang tepat untuk menanganinya.

a. Missing Value

Berdasarkan hasil pengecekan `df.isnull()` terhadap semua variabel tidak ditemukan *missing value* sehingga tidak diperlukan penanganan khusus seperti penghapusan *row* (jika data yang hilang hanya sekitar 1-5% dari total dataset) atau imputasi nilai kosong tersebut dengan rata-rata, median (cocok untuk variabel numerik karena lebih *robust* dibandingkan mean) atau modus (untuk variabel kategorikal). Setelah proses transformasi data dilakukan kembali validasi terhadap *missing value* untuk memastikan tidak ada *missing value* akibat proses transformasi.

• b. Outlier Detection

Outlier detection dilakukan untuk mengidentifikasi nilai ekstrim yang menyimpang secara signifikan dari distribusi data. Hal ini penting untuk dilakukan karena keberadaan *outlier* dapat mempengaruhi hasil analisis statistik. Dalam tahap ini dilakukan dua pendekatan yaitu:

1. Interquartile Range Method (IQR)

Metode ini digunakan untuk mendeteksi *outlier* berdasarkan sebaran data kuartil. Metode ini diterapkan pada variabel numerik seperti *age*, *purchase amount (usd)*, *review rating*, dan *previous purchase* dimana batas outlier ditentukan dengan rumus:

- $Lower\ Bound = Q1 - 1.5 \times IQR$
- $Upper\ Bound = Q3 + 1.5 \times IQR$

Dimana Q1 adalah kuartil pertama (25%), Q3 adalah kuartil ketiga (75%) dan IQR adalah Q3-Q1. Jika nilai berada diluar rentang tersebut maka dikategorikan sebagai *outlier*. Hasil deteksi tersebut tidak ditemukan data yang berada di luar batas IQR pada seluruh variabel numerik sehingga tidak perlu penanganan lebih lanjut. Selain itu, digunakan juga visualisasi dengan *boxplot* untuk memvalidasi temuan ini.

2. Z-Score Method

Sebagai validasi tambahan metode *z-score* [`stats.zscore()`] juga dilakukan dengan *threshold* $|Z| > 3$ sebagai batas untuk mendeteksi *outlier*. Jika nilai yang berada lebih dari tiga standar deviasi dari rata-rata dianggap sebagai nilai ekstrim dan berpotensi sebagai *outlier*. Hasil dari pengecekan tersebut tidak ditemukan *outlier* sehingga secara keseluruhan dataset relatif bersih dan stabil.

3.3 Transformations and derived variables

Beberapa *data transformation* and *feature engineering* dilakukan untuk meningkatkan kualitas data untuk proses analisis. Proses tersebut meliputi :

1. Data Transformation

- a. Encoding Variable Biner

Proses ini dilakukan untuk mengubah variabel kategorikal biner (*yes/no*) menjadi format numerik (*Yes* = 1 dan *No* = 0) agar dapat diproses dalam analisis kuantitatif seperti korelasi. Dalam dataset

beberapa kolom yang memiliki nilai kategorik biner adalah *Subscription Status*, *Discount Applied*, dan *Promo Code Used*.

- b. Standarisasi Data Kategorikal Proses ini dilakukan dengan menyamakan kategori dengan makna serupa pada kolom *Frequency of Purchases* seperti “*Every 3 Months*” dan “*Quarterly*” serta “*Bi-Weekly*” dengan “*Fortnightly*”.
- c. *Feature Selection / Data Reduction*
 - Dalam proses ini kolom yang dianggap kurang relevan dengan kebutuhan analisis dihapus seperti *CustomerID*, *Size* dan *Color*.

2. Feature Engineering

- Terdapat 2 variabel turunan baru yang ditambahkan yaitu :
 - *Age Group* : mengkategorikan pelanggan menjadi *Young Adult* (18-29 tahun), *Adult* (30-49 tahun), dan *Senior* (50-100 tahun) karena perlu menyederhanakan variasi data menjadi segmen pelanggan yang lebih bermakna sehingga *customer behaviour* dan daya beli tiap kelompok bisa lebih mudah dianalisis.
 - *Purchase Frequency Tier* : mengelompokkan frekuensi pembelian menjadi *High* (*Weekly, Fortnightly*), *Medium* (*Monthly*) dan *Low* (*Quarterly, Annually*) sehingga memudahkan analisis pola loyalitas dan frekuensi transaksi pelanggan.

Penambahan variabel turunan ini dilakukan untuk mempermudah analisis, meningkatkan interpretasi dan mendukung identifikasi *customer behaviour* yang lebih maksimal.

3.4 Resulting dataset (data dictionary after wrangling)

Dataset Customer Shopping Behaviour yang digunakan berisi 3900 baris data unik transaksi pelanggan dengan 17 variabel yang menyimpan informasi demografis, perilaku pembelian dan feedback dari customer. Berikut adalah key variables dan deskripsinya :

Variabel	Tipe Data	Deskripsi	Values
Age	Numerical (INT)	Usia pelanggan	18 - 70 Tahun
Gender	Categorical (String)	Jenis kelamin pelanggan	Male, Female
Item Purchased	Categorical (String)	Nama produk yang dibeli	Blouse, Sweater, Jeans, Sandals, Sneakers, dst
Category	Categorical (String)	Kategori produk	Clothing, Footwear, Outerwear, Accessories
Purchase Amount (USD)	Numerical (INT)	Jumlah pembelian	20 -100 USD
Location	Categorical (String)	Lokasi pelanggan	Kentucky, Maine, Massachusetts, Rhode Island, Oregon, dst
Season	Categorical (String)	Musim pembelian	Winter, Spring, Summer, Fall
Review Rating	FLOAT	Rating produk	2.5 - 5.0

Season	Categorical(S tring)	Musim pembelian	Winter, Spring, Summer, Fall
Subscription Status	BOOLEAN	Status langganan pelanggan	Yes, No
Shipping Type	Categorical(S tring)	Metode Pengiriman	Express, Free Shipping, Next Day Air, Standard, 2-Day Shipping, Store Pickup
Discount Applied	BOOLEAN	Apakah diskon digunakan?	1 (yes),0(no)
Promo Code Used	BOOLEAN	Apakah kode promo digunakan?	1 (yes),0(no)
Previous Purchases	INT	Jumlah pembelian sebelumnya	1-50
Payment Method	Categorical(S tring)	Metode Pembayaran	Venmo, Cash, Credit Card, PayPal, Bank Transfer, Debit Card
Frequency of Purchases	Categorical(S tring)	Frekuensi pembelian	Fortnightly, Weekly, Annually, Quarterly, Monthly
Age Group	Categorical(S tring)	Kategori kelompok usia	Young Adult, Adult, Senior
Purchase Frequency Tier	Categorical(S tring)	Kategori kelompok pembelian	Low, Medium, High

Variabel utama yang digunakan untuk visualisasi yakni variabel numerik (*Purchase Amount (USD)* , *Previous Purchases* , and *Review Rating*) yang digunakan untuk menganalisis distribusi, korelasi, dan perbandingan melalui visualisasi seperti *scatter plot*, *bar chart* dan *box plot* . Misalnya, *Purchase Amount* digunakan untuk memeriksa pola pengeluaran, sedangkan *Previous Purchases* membantu menilai perilaku loyalitas pelanggan. Selain itu, variabel kategori seperti *Gender*, *Purchase Frequency Tier* , *Age Group* dan *Product Category* digunakan untuk analisis komparatif antar kelompok yang divisualisasikan menggunakan *bar chart* untuk mengidentifikasi perbedaan dalam perilaku belanja atau segmentasi pelanggan.

4. Exploratory Data Analysis & Exploratory Visualization

4.1 Descriptive statistics

Descriptive statistics adalah metode untuk memberikan gambaran umum mengenai karakteristik data numerik. *Descriptive statistics* mencakup *mean*, *median* dan *min-max* agar lebih mudah dipahami.

Variable	Mean	Median	Min	Max	Std Dev	Range
Age (tahun)	44.07	44.0	18	70	15.21	52
Purchase Amount (USD)	59.76	60.0	20	100	23.69	80
Review Rating	3.75	3.7	2.5	5.0	0.72	2.5

Previous Purchases	25.35	25.0	1	50	14.45	49
Subscription Status	0.27	0	0	1.0	0.44	1.0
Discount Applied	0.43	0	0	1.0	0.495	1.0
Promo Code Used	0.43	0	0	1.0	0.495	1.0

- *Age* Rata-rata usia pembeli adalah 44 tahun, dengan rentang antara 18 (min) hingga 70 (max) tahun. Nilai median dari variabel usia adalah 44 dan standar deviasi 15.21 yang menunjukkan variabilitas yang cukup luas (rangennya 52) namun masih dalam batas wajar sehingga ini menunjukkan bahwa pelanggan tersebar dari yang muda hingga yang cukup tua. Nilai median dan mean yang hampir sama menunjukkan distribusi yang simetris.
- *Purchase Amount (USD)* Rata-rata transaksi sebesar \$59.76, dengan nilai minimum \$20 dan maksimum \$100. Median dari variabel ini adalah \$60 dan standar deviasi 23,69. Hal ini menunjukkan distribusi yang simetris karena nilai mean dan median hampir sama. Namun *range* yang tinggi (\$80) menunjukkan variabilitas moderat dalam belanja pelanggan. Ini menunjukkan bahwa meskipun pola pembelian secara keseluruhan stabil dan dapat diprediksi, masih terdapat perbedaan nyata antara pelanggan dengan pembelian rendah dan pembelian tinggi.
- *Rating Review* Rata-rata kepuasan pelanggan berada di angka 3.75 dari skala 5. Ini menunjukkan performa yang baik namun belum sempurna. Angka ini berada di atas nilai tengah (2.5), yang berarti mayoritas pelanggan merasa puas dalam tingkat sedang hingga tinggi. *Range* yang kecil (2.5) dan standar deviasi yang kecil 0.72 menunjukkan nilai terkumpul di sekitar rata-rata sehingga secara keseluruhan pengalaman mereka tetap mirip.
- *Previous Purchase*

Nilai rata-rata (\$ 25.35) dan nilai tengah (\$25) yang hampir identik menunjukkan bahwa data terdistribusi secara simetris. Variabel *previous purchase* memiliki variabilitas yang tinggi dengan standar deviasi 14.45 yang menunjukkan adanya perbedaan antara pelanggan di area dingin dan area panas. Karena variansinya tinggi maka harus dilakukan segmentasi untuk strategi bisnis.


- Variabel Biner (*Subscription Status* , *Discount Applied* , dan *Promo Code Used*) Variabel tersebut memiliki nilai rata-rata sebesar 0.27, 0.43 dan 0.43 yang menunjukkan proporsi pelanggan yang menggunakan fitur tersebut.

4.2 Distributions and comparisons

Dalam EDA visualisasi digunakan untuk memahami distribusi data dan membandingkan pola antar variabel sehingga disini visualisasi membantu mengidentifikasi pola, tren atau hubungan yang mungkin susah terlihat melalui data statistik saja.


1. Distribusi Data

a. Distribusi data *Purchase Amount (USD)*




Histogram distribusi *purchase amount (USD)* menunjukkan pola distribusi yang relatif ” *uniform* ” (rata) karena tidak ada penumpukan angka di tengah (tidak membentuk *Bell Curve*). Nilai pembelian tersebar dari rentang \$20 hingga \$100. Terdapat sedikit peningkatan pada rentang harga rendah (\$20-\$30) yang mengindikasikan kemungkinan adanya perbedaan preferensi belanja. Selain itu, tidak terdapat kemiringan tertentu (*left-skewed* atau *right-skewed*). Hal ini menunjukkan bahwa pengeluaran pelanggan cukup beragam tanpa ada dominasi pada jumlah pembelian tertentu seperti belanja dalam nominal sedikit dengan belanja dengan nominal besar. Dari grafik tersebut juga tidak terlihat adanya data outlier yang ekstrim sehingga data dalam rentang yang stabil.

b. Distribusi *Previous Purchase*




Pola distribusi *previous purchase* terlihat sangat rata. Jumlah pelanggan yang baru sedikit membeli hampir sama banyaknya dengan pelanggan yang sudah belanja 25 kali maupun 50 kali. Ini menunjukkan bahwa perusahaan memiliki retensi pelanggan yang sangat stabil. Tidak ada penurunan drastis pada jumlah pelanggan lama. Namun, karena distribusinya rata, perusahaan belum berhasil mendorong mayoritas pelanggan untuk menjadi ” *Super Loyal* ” (tidak ada penumpukan di angka 50).

c. Distribusi Usia



Berdasarkan grafik terlihat bahwa distribusi usia pelanggan menunjukkan pola yang relatif merata di seluruh rentang usia mulai dari 18 hingga 70 tahun. Hal ini berarti segmentasi usia pelanggan tersebar merata di semua kelompok usia.


d. Distribusi Rating



Berdasarkan grafik dapat ditemukan bahwa sebagian besar *rating* tersebar dari 2.5 hingga 5 dengan distribusi yang merata tidak ada kecenderungan di area tertentu sehingga ini menunjukkan bahwa variabilitas rendah sehingga persepsi pelanggan terhadap pengalaman belanja cenderung serupa.


2. Perbandingan

a. Perbandingan Purchase Amount by Payment Method




Rata-rata nominal belanja (*Purchase Amount*) hampir identik di semua metode pembayaran, yaitu di kisaran \$60. Hal ini membuktikan bahwa pilihan metode pembayaran tidak mempengaruhi daya beli pelanggan.

b. Perbandingan Efek Discount & Subscription Pada Purchase Amount (USD)




Rata-rata *Purchase Amount* tetap berada di kisaran yang sama (sekitar \$60) baik saat diskon atau subscription diterapkan (1) maupun tidak (0). Diskon saat ini berfungsi untuk menarik volume transaksi, tetapi belum berhasil mendorong pelanggan untuk “belanja lebih banyak” (*upselling*). *Subscription* juga belum memberikan nilai tambah finansial bagi perusahaan dalam hal besaran belanja.

- c. Perbandingan *Purchase Amount (USD)* berdasarkan *Frequency Tier*



Kelompok pelanggan dengan frekuensi “High” nilai belanja per transaksinya tidak berbeda jauh dengan pelanggan tahunan (*Annually*). Ini menunjukkan bahwa pelanggan yang sering datang (*High Frequency*) bisa menjadi aset berharga untuk pemasukan tapi mereka masih berbelanja dalam jumlah kecil per kunjungan.

- d. Perbandingan Category dengan Purchase Amount (USD)




Berdasarkan grafik tersebut dapat terlihat bahwa semua kategori memiliki nilai median yang hampir sama yaitu sekitar \$60. Ini bisa menunjukkan bahwa strategi harga perusahaan sangat konsisten di seluruh lini produk. Tidak ada satu kategori yang dianggap pelanggan terlalu mahal dibanding yang lain.

Berdasarkan visualisasi distribusi dan komparasi yang dilakukan dapat ditemukan bahwa :

- Distribusi *Purchase Amount*, *Age*, *Rating* maupun *Previous Purchase* menunjukkan pola yang relatif merata (*uniform*)
- Nilai median perbandingan *Purchase Amount* dengan *Category*, *Payment Method*, *Frequency Tier*, *Subscription Status* dan *Effect Discount* menunjukkan kesamaan antar kategorinya sehingga tidak ada perbedaan yang signifikan dalam nilai pembelian berdasarkan variabel-variabel tersebut.

Oleh karena itu, analisis visualisasi ini menunjukkan bahwa perilaku pembelian pelanggan cenderung kompleks sehingga diperlukan analisis lebih lanjut untuk menggali insight yang lebih mendalam.

4.3 Patterns, trends and relationships



Hampir semua kotak dalam *heatmap* memiliki warna yang cenderung pucat dengan angka mendekati 0. Secara statistik, tidak ada variabel yang memiliki hubungan sebab-akibat yang kuat. Ini membuktikan bahwa perilaku belanja pelanggan dipengaruhi oleh faktor-faktor eksternal lain di luar data demografi yang tersedia (seperti kebutuhan mendesak). Contoh korelasinya :

- Korelasi antara *Age* dan *Purchase Amount* : -0.01
- Korelasi antara *Previous Purchases* dan *Purchase Amount* : 0.01
- Korelasi antara *Review Rating* dan *Purchase Amount* : 0.03

Berdasarkan *heatmap* tersebut dapat disimpulkan bahwa tidak terdapat hubungan linear yang signifikan antar variabel sehingga perilaku pembelian pelanggan tidak dipengaruhi oleh variabel-vari dominan saja tapi cenderung lebih kompleks sehingga butuh analisis lebih lanjut. Selain itu, berdasarkan hasil eksplorasi data dan analisis korelasi, ditemukan lima pola dan tren yang menggambarkan perilaku pelanggan:

- ***Age-Agnostic Spending Behavior (Pattern Keseragaman Daya Beli)*** Berdasarkan *Heatmap* (korelasi usia vs jumlah pembelian = -0.01) ini menunjukkan bahwa daya beli pelanggan tidak dipengaruhi oleh usia. Ini berarti seluruh kelompok usia (Young Adult, Adult, Senior) memiliki median belanja yang hampir identik di angka ~\$60. Oleh karena itu, strategi promosi yang terlalu tersegmentasi berdasarkan umur saja kurang cocok sebagai strategi bisnis.

- ***Low Retention Correlation (Anomali Loyalitas Pelanggan)*** Berdasarkan *Heatmap* korelasi antara jumlah pembelian sebelumnya dengan jumlah belanja saat ini sangat lemah (0.01) yang berarti pelanggan setia tidak kemudian akan berbelanja lebih banyak daripada pelanggan baru. Ini bisa menunjukkan bahwa strategi *Loyalty Program* yang ada masih kurang maksimal sehingga bisa di tingkatkan lagi semisal dengan strategi *tiered discount* (misal: diskon khusus untuk pembelian ke-5 di atas \$100) untuk mendorong peningkatan *Customer Lifetime Value* (CLV).


Putusnya Hubungan Kepuasan dengan Keuntungan (Low Correlation) Korelasi antara *Review Rating* dan *Purchase Amount* mendekati nol (0.03). Pelanggan yang memberikan rating tinggi ternyata tidak belanja lebih banyak, dan pelanggan dengan belanja besar pun belum tentu memberikan

rating tinggi. Ini menunjukkan bahwa pengalaman belanja (*customer experience*) belum terkonversi optimal menjadi keuntungan.

Discount dan Subscription Tidak Meningkatkan Nilai Pembelian

Berdasarkan analisis terhadap boxplot tidak ditemukan perbedaan signifikan antara Purchase Amount pelanggan yang menggunakan Discount atau Subscription dengan yang tidak sehingga perusahaan bisa mempertimbangkan strategi seperti bundling dan memaksimalkan benefit subscription..

Seasonal Trend Analysis



Grafik tersebut menunjukkan bahwa volume transaksi tersebar relatif merata di keempat musim (*Winter, Spring, Summer, Fall*) untuk semua kategori produk. Tidak ada musim dominan yang secara signifikan mampu mendorong pembelian lebih tinggi. Hal ini berarti pola pembelian konsisten sepanjang tahun tanpa dipengaruhi musim.

Secara keseluruhan, hasil analisis menunjukkan bahwa nilai pembelian cenderung *uniform* di berbagai kondisi (tidak ada pattern/segmentasi yang terlihat jelas). Selain itu, tidak terdapat hubungan korelasi yang signifikan antara variabel perilaku pelanggan dengan *purchase amount* sehingga perilaku pengeluaran pelanggan dalam dataset ini tidak dapat dijelaskan oleh variabel yang tersedia. Kondisi ini juga menunjukkan bahwa faktor-faktor seperti usia, gender, diskon, dan subscription bukan variabel dominan yang mempengaruhi nilai transaksi. Oleh karena itu, perusahaan perlu mempertimbangkan variabel lain yang lebih spesifik, seperti personalisasi penawaran, upselling, cross-selling, dan penguatan loyalty program untuk mendorong nilai transaksi.

4.4 Visualization-related data challenges

Berdasarkan hasil eksplorasi data ditemukan beberapa tantangan seperti :

- Distribusi *Purchase Amount* terlihat seragam dibandingkan distribusi normal (*bell curve*) sehingga histogram menjadi tidak bisa menunjukkan pola yang kuat karena tidak terdapat puncak distribusi yang dominan.
- Banyak variabel seperti *Gender, Previous Purchase* , dan *Purchase Amount* yang ketika divisualisasikan dengan *scatter plot* menghasilkan 3900 data saling *overlap* dimana ini menyebabkan *overplotting* karena kepadatan data tidak terlihat secara akurat. Selain itu, jika data sebanyak itu menumpuk akan mengganggu fokus pada *trendline* jika tidak diatasi.
- Nilai nilai (median pembelanjaan) yang mirip sehingga tumpang tindih di berbagai kategori produk sehingga sulit menunjukkan perbedaan yang jelas antar kelompok secara visual dengan *box plot* .

Secara keseluruhan tantangan-tantangan tersebut memerlukan pemilihan visual yang tepat untuk mencegah salah tafsir dan menjamin *insight* yang bermanfaat dari informasi tersebut tersampaikan dengan baik.

Effect of each challenge on visual interpretation

Setiap tantangan dalam dataset tersebut bisa mempengaruhi bagaimana informasi dipahami jika salah dalam pemilihan chart maupun pengaturan visual seperti warna, ukuran, posisi dan lainnya.

Ketika mengamati distribusi *Purchase Amount* yang merata hanya dengan mengandalkan histogram mungkin hanya bisa menunjukkan bahwa tidak ada tren yang signifikan. Oleh karena itu diperlukan alat visual tambahan seperti *box plot* agar informasi penting seperti rentang atau perbedaan yang halus tidak terlewatkan.

Kemudian, *scatter plot* tidak diatur transparansinya maka semua titik akan menumpuk di koordinat yang sama sehingga pembaca akan kesulitan membedakan titik yang berdiri sendiri dan yang menumpuk sehingga distribusi data yang asli menjadi tersembunyi dan bisa menimbulkan misinterpretasi.


Distribusi antar kategori yang tumpang tindih seperti median yang sebanding dalam *box plot* dapat membuat perbandingan antar kelompok menjadi lebih sulit. Jika menggunakan visualisasi yang kurang tepat seperti diagram batang bertumpuk dapat membesar-besarkan atau menyembunyikan variasi, sehingga mengakibatkan interpretasi yang salah terhadap kinerja berbagai kategori.

Selain itu, penataan yang buruk dan warna yang berlebihan juga dapat membingungkan pembaca dan mengurangi pemahaman karena bisa saja menonjolkan pola yang tidak penting, atau menyembunyikan wawasan yang signifikan. Oleh karena itu, sangat penting untuk membuat keputusan yang tepat mengenai jenis grafik dan pemilihan visual untuk memfasilitasi analisis yang akurat.


4.5 Exploratory visualizations in Tableau

Untuk mengeksplorasi dataset dari berbagai sudut pandang analisis digunakan 3 perspektif seperti :


1. Perspektif perbandingan, menggunakan *bar chart* untuk membandingkan performa rata-rata transaksi antar kategori produk dan gender. Bar chart dipilih karena efektif dalam menampilkan perbandingan nilai agregat antar kategori melalui perbedaan panjang.



2. Perspektif distribusi, menggunakan *boxplot purchase amount distribution by age group* untuk melihat sebaran nilai dan median pembelian berdasarkan *age group*. Visualisasi ini digunakan untuk menghindari kesalahan interpretasi yang dapat muncul jika menggunakan nilai rata-rata saja.



3. Perspektif hubungan, menggunakan *scatter plot* dengan trendline untuk melihat hubungan antara loyalitas (jumlah pembelian sebelumnya) dengan nilai transaksi rata-rata.



Visualisasi-visualisasi tersebut memungkinkan untuk identifikasi perbedaan atau kesamaan dalam rata-rata pengeluaran, *variability* dan distribusi dalam setiap kategori sehingga bisa diketahui faktor mana yang mempengaruhi perilaku belanja pengguna.

Visual patterns observed

Dari ketiga grafik yang dibuat ditemukan pola sebagai berikut:

1. Purchase Amount Distribution by Age Group (Box Plot) Berdasarkan grafik tersebut dapat ditemukan pola bahwa tidak ada pengaruh yang signifikan dalam antara kelompok *adult*, *senior* dan *young adult* karena semua kelompok usia memiliki perilaku *spending* yang mirip. Variasi tiap kelompok juga lebih besar daripada perbedaan antar kelompok. Temuan *pattern* ini didukung dengan fakta yang bisa dilihat dari grafik bahwa median untuk ketiga kategori berada di sekitar \$60 dengan rentang kuartil berada di antara \$40 hingga \$80. Selain itu, kotak IQR antar kelompok usia sangat overlap. Dalam grafik ini juga tidak terlihat adanya *outliers* yang ekstrem atau perbedaan signifikan dalam daya beli antar generasi.

2. Relationship Between Previous Purchases and Avg Purchase Amount by Gender (Scatter Plot)

Berdasarkan grafik dapat terlihat bahwa garis *trend line* terlihat sepenuhnya datar (horizontal) di sekitar \$60. Untuk menghindari penumpukan data dari total 3900 observasi maka grafik ini menggunakan metode agregasi dimana setiap titik mewakili nilai rata-rata pembelian untuk tiap frekuensi pembelian tertentu sehingga tren hubungan antara loyalitas pelanggan dan nilai transaksi dapat terlihat lebih jelas secara struktural. Grafik tersebut menunjukkan bahwa baik pelanggan baru (pembelian <5) maupun pelanggan lama (pembelian > 30) memiliki rata-rata belanja yang sama di kisaran \$60. Ini menunjukkan bahwa tidak ada hubungan kuat antara jumlah pembelian sebelumnya, gender dan rata-rata purchase amount dimana loyalitas atau pengalaman berbelanja sebelumnya tidak meningkatkan *basket size* pelanggan.

- ## 3. Average Purchase Amount by Category and Gender (Bar Chart)
- Grafik tersebut menunjukkan bahwa perbedaan kategori sangat tipis (~\$5). Kategori *acesories* pada wanita memiliki rata-rata tertinggi (\$60.76) sedangkan *outerwear* pada pria adalah yang terendah (\$56.60). Untuk male pembelian sedikit lebih tinggi di *footwear*. Selain itu, perbedaan *spending* gender juga kecil dengan selisih \$1–\$2. Karena selisih rata-rata tinggi bar mirip (sekitar \$56–61) ini menandakan produk yang dijual kemungkinan besar berada dalam segmen harga ” *mass-market* ” yang seragam (misalnya semua barang dipukul rata di kisaran harga yang mirip). Selain itu, perbedaan antar gender sangat kecil sehingga segmen gender lemah.

Limits of interpretation

Meskipun visualisasi bisa memberikan insight yang berharga untuk bisnis, tetap ada keterbatasan dalam interpretasi.

1. Apa yang disarankan visualisasi :
 - a. Stabilitas harga, bahwa produk kemungkinan besar dijual dengan rentang harga yang tetap sehingga tidak ada segmen pelanggan yang belanja jauh lebih mahal dari segmen lainnya.
 - b. Target pasar luas, dimana grafik *boxplot* menunjukkan bahwa bisnis memiliki daya tarik yang merata di semua kategori usia pelanggan sehingga usia tidak memiliki pengaruh yang kuat terhadap perilaku *spending* .
 - c. *Purchase amount* relatif konsisten di semua segmen serta tidak ada pengaruh frekuensi pembelian sebelumnya dengan nilai pembelian. Ini bisa menunjukkan bahwa program loyalitas *customer* masih kurang cukup kuat untuk mendukung *upselling*.

Secara keseluruhan, pola-pola dari visual ini menunjukkan bahwa tidak ada hubungan yang kuat atau perbedaan signifikan antara kelompok dalam kumpulan data.

- ## 2. Hal-hal yang tidak bisa disimpulkan
- a. Berdasarkan visual tidak bisa disimpulkan kelompok mana yang paling menguntungkan. Meskipun rata-rata belanja sama (~\$60) jika jumlah antar kelompok berbeda drastis seperti *young adult* 100 sedangkan *senior* mencapai ribuan maka *senior* jauh lebih penting dari bisnis.
 - b. Berdasarkan *scatter plot* kita tidak bisa menyimpulkan bahwa program loyalitas gagal meskipun nilai belanja per transaksi tidak naik (tetap di \$60) berdasarkan hubungannya dengan *previous purchase* . Mungkin ada faktor-faktor lain yang mempengaruhi dimana belum tergambar di rata-rata per transaksi ini seperti *income customer* .

- c. Meskipun secara visual mirip dari bar chart, tanpa uji statistik seperti ANOVA atau T-Test kita tidak bisa memastikan secara ilmiah apakah perbedaan kecil antara pria dan wanita di kategori tertentu terjadi secara kebetulan atau memang ada pola perilaku yang berbeda.
- d. Tidak memasukkan *additional* faktor yang sekiranya relevan seperti season, discounts, dan subscription tidak dimasukkan dalam grafik dimana variabel ini mungkin bisa mempengaruhi nilai pembelian sekalipun sedikit.

Kesimpulannya, data ini menunjukkan kondisi yang relatif homogen antar kelompok umur, jenis kelamin, kategori produk, dan frekuensi pembelian. Namun karena keterbatasan analisis visual, temuan dari visualisasi ini harus diperlakukan sebagai wawasan awal dan harus didukung oleh analisis lebih lanjut sebelum menarik kesimpulan yang pasti.

4.6 Early visualization design: one question, one chart

Focused analytical question

Pertanyaan analisis yang difokuskan dalam visualisasi ini adalah : “Apakah terdapat perbedaan yang signifikan dalam distribusi jumlah pembelian (*purchase amount*) di antara pelanggan dengan tingkat frekuensi pembelian yang berbeda (*Low, Medium* , dan *High*)?”


Pertanyaan ini dipilih dengan mempertimbangkan beberapa aspek seperti :

- a. Pertanyaan hanya melibatkan dua variabel utama yaitu
- Variabel kategorikal : *Purchase Frequency Tier (Low, Medium, dan High)*
- Variabel numerik : *Purchase Amount (USD)*
- b. Pertanyaan ini tidak hanya sekedar berfokus pada nilai rata-rata tetapi pada keseluruhan distribusi data termasuk median, sebaran data, variasi antar pelanggan dan potensi perbedaan pola pembelian.
- c. Pertanyaan ini bersifat *comparative analysis* yang membandingkan antar kelompok sehingga sangat sesuai untuk divisualisasikan menggunakan satu grafik saja yang bisa menampilkan banyak distribusi sekaligus

Oleh karena itu, pertanyaan ini sudah terfokus dan bisa dijawab menggunakan satu visualisasi saja serta sangat relevan untuk pengambilan keputusan bisnis khususnya dalam menentukan apakah frekuensi pembelian bisa digunakan sebagai dasar segmentasi pelanggan seperti apakah kelompok ” *High Frequency* ” sebenarnya menyumbang total uang yang jauh lebih besar bagi perusahaan.

Primary visualization

Visualisasi utama yang digunakan untuk menjawab pertanyaan tersebut adalah boxplot dengan desain visual sebagai berikut :



- a. Sumbu X (*horizontal axis*) yang menampilkan kategori *Purchase Frequency Tier* (Low, Medium, dan High)
- b. Sumbu Y (*vertical axis*) yang menampilkan nilai numerik *Purchase Amount(USD)*
- c. Komponen dalam setiap boxplot terdiri dari:
 1. *Interquartile Range* (IQR) di area box (Q1-Q3) yang menunjukkan seberapa tersebar 50% data tengah
 2. *Whiskers* (garis atas dan bawah) menunjukkan rentang data (min-max)
 2. Titik-titik data (*scatter overlay*) yang menunjukkan distribusi individual data
 3. Median yang ditunjukkan dengan garis tengah dalam area box yang menggambarkan nilai tengah pembelian

Visualisasi ini memungkinkan pembaca dengan mudah membandingkan nilai tengah antar kategori, mengamati variasi data dalam setiap kelompok, dan mengidentifikasi apakah terdapat perbedaan distribusi yang signifikan secara cepat.

Design justification

1. Chart Selection

- Pemilihan boxplot didasarkan pada tujuan analisis yaitu membandingkan distribusi numerik antar beberapa kategori. *Bar chart* tidak dipilih karena hanya menunjukkan nilai rata-rata dan bisa menyembunyikan variasi data. Histogram juga tidak dipilih karena kurang efektif dalam membandingkan lebih dari satu kategori secara langsung. Tipe grafik ini dipilih karena memiliki beberapa keunggulan seperti
 - a. Merepresentasikan distribusi yang komprehensif
 - Jika dibandingkan dengan grafik seperti bar chart yang hanya menampilkan nilai rata-rata, boxplot memberikan informasi yang lebih lengkap karena terdapat median, range data, dan variabilitas (IQR). Menampilkan informasi tersebut penting karena kelompok-kelompok bisa memiliki nilai rata-rata yang sama tetapi distribusi yang berbeda.

- b. Bisa membandingkan kategori dengan mudah
 - Boxplot memungkinkan beberapa distribusi ditampilkan secara berdampingan di dalam satu visualisasi sehingga memudahkan pembaca dalam membandingkan distribusi antar kelompok serta memudahkan dalam mengidentifikasi pola perbedaan atau kesamaan.

Oleh karena itu, box plot merupakan pilihan yang paling sesuai karena memberikan keseimbangan antara kelengkapan informasi dan kemudahan untuk interpretasi.

2. Pemilihan *Visual Encoding*

Pemilihan visual mempertimbangkan beberapa aspek berikut:

• a. Posisi

Posisi merupakan *encoding visual* yang paling akurat dalam persepsi manusia sehingga pemilihan posisi sangat mempengaruhi kemudahan dalam membandingkan nilai secara langsung dengan presisi tinggi. Posisi *horizontal* direpresentasikan *purchase frequency tier* karena merupakan variabel kategorikal dan berfungsi sebagai pengelompokan data. Posisi vertikal merepresentasikan *purchase amount* karena merupakan variabel numerik yang dianalisis distribusinya dalam tiap kategori. Penempatan ini mengikuti prinsip umum visualisasi data dimana variabel kategorikal ditempatkan di sumbu diskrit sedangkan variabel numerik ditempatkan di sumbu kontinu.

• b. Panjang

Tinggi box menunjukkan IQR dengan panjang *whisker* yang menunjukkan rentang data sehingga ini bisa memberikan *insight* tentang konsistensi perilaku pembelian dan variabilitas dalam setiap kelompok. Misalnya jika box besar berarti IQR besar yang menunjukkan pelanggan memiliki perilaku pembelian yang beragam sedangkan jika ukuran box kecil maka pembelian cenderung konsisten. Pemilihan box dipilih karena mata manusia sangat akurat dalam membandingkan perbedaan panjang batang.

• c. Warna

Digunakan warna yang seragam dengan gradasi variasi yang lembut untuk menghindari distraksi visual, meningkatkan *readability* dan menjaga tampilan agar tetap profesional. Warna biru muda dipilih untuk box karena memberikan kesan stabil dan tidak mengganggu fokus utama visualisasi yaitu distribusi data. Penggunaan warna lembut membantu meningkatkan keterbacaan secara visual tanpa menambah distraksi visual yang tidak diperlukan karena perbedaan kategori sudah direpresentasikan melalui posisi pada sumbu x.

• d. Titik Data

Titik-titik kecil ditambahkan di *whisker* untuk menunjukkan data individual sehingga membantu mengidentifikasi kepadatan dan pola clustering serta memberikan transparansi terhadap distribusi data.

3. Desain *Trade-Offs*

• a. Kejelasan dengan Detail

- Boxplot menyederhanakan data menjadi ringkasan sehingga mudah dipahami tapi terbatas karena tidak menunjukkan bentuk distribusi secara detail seperti *skewness*

secara eksplisit. Penambahan titik data (*scatter overlay*) memberikan transparansi terhadap distribusi nilai individual namun tidak secara efektif menunjukkan bentuk distribusi seperti *skewness* yang disebabkan tidak adanya representasi kepadatan data sehingga untuk analisis *skewness* yang lebih akurat bisa ditambahkan visualisasi seperti histogram karena mampu menunjukkan bentuk distribusi secara eksplisit.

- b. *Simplicity* dengan *Information Richness*
- Keuntungan dari visualisasi boxplot yang dipilih adalah visualisasi tetap sederhana dan tidak membingungkan tetapi memiliki keterbatasan karena tidak semua informasi statistik ditampilkan secara eksplisit. Namun karena tujuan yang ingin dianalisis hanya komparasi maka informasi yang ditampilkan sudah cukup representatif.
- c. *Overplotting* dengan *Insight*
- Penambahan titik data dapat menyebabkan *overplotting* karena titik saling tumpang tindih sehingga distribusi aktual tidak terlihat jelas. Namun keberadaan titik tetap memberikan gambaran umum mengenai sebaran nilai individual dan membantu meningkatkan transparansi data dibandingkan hanya menampilkan ringkasan statistik. Oleh karena itu, *trade off* ini menghasilkan keseimbangan antara transparansi data dan keterbacaan visual meskipun tidak sepenuhnya optimal.

Berdasarkan visualisasi dapat diperoleh *insight* bahwa median *purchase amount* untuk ketiga kategori berada di kisaran yang hampir sama (~\$60) dengan IQR antar kategori juga sangat mirip (\$40–\$80). Rentang data (\$20–100) juga konsisten di semua kelompok. Temuan ini dapat diinterpretasikan bahwa frekuensi pembelian tidak menunjukkan hubungan yang kuat terhadap besarnya pengeluaran per transaksi dimana pelanggan dengan frekuensi pembelian tinggi tidak selalu belanja lebih banyak dibandingkan pelanggan dengan frekuensi rendah. Implikasi bisnis yang bisa diperoleh adalah segmentasi berdasarkan frekuensi pembelian saja tidak bisa menjadi indikator utama untuk meningkatkan nilai transaksi per pelanggan dan diperlukan analisis lanjutan untuk mengidentifikasi faktor lain yang mempengaruhi.

Phase 2 — Depth: Evaluation, Advanced Analysis, Prediction and Communication

Phase 2 re-uses the Phase 1 cleaned dataset, first checks how well the wrangling worked, then extends the analysis with segmentation, statistical testing and a subscription-prediction model, and finally communicates the findings in a four-page Tableau dashboard and a set of recommendations.

5. Data Quality Review & Evaluation

Implementation: notebooks/02_data_quality_evaluation.ipynb.

5.1 Data quality issues identified in Phase 1

RINGKASAN MASALAH KUALITAS DATA RAW		
Kategori Masalah	Jumlah	Status
Missing Values	0	Bersih
Duplicate Rows	0	Bersih
Invalid / Out-of-Range Values	0	Bersih
Category Inconsistency (kolom)	1	Perlu ditangani
Data Outlier	0	Bersih

Gambar 1. Summary Masalah Kualitas Data Pada Phase 1

Dataset retail yang digunakan dalam *project* ini terdiri dari 3900 *row* data dengan 18 fitur bawaan yang berisi informasi pembelian, demografis pelanggan, dan *rating* dari pelanggan. Hasil evaluasi yang didapatkan pada Phase 1 menunjukkan bahwa kualitas data *raw* sudah cukup baik namun masih memiliki beberapa masalah yang harus diselesaikan pada tahap Phase 1. Permasalahan kualitas data yang berhasil diselesaikan pada Phase 1 adalah menangani inkonsistensi kategori dalam variabel kategorikal.

Fitur *Frequency of Purchases* memiliki nilai unik ” *Quarterly* ” dan ” *Every 3 Months* ” serta ” *Bi-weekly* ” dan ” *Fortnightly* ” yang memiliki makna sama. Adanya kesalahan ini akan membuat sistem membaca keempat kategori tersebut sebagai kategori yang berbeda sehingga hasil analisis menjadi kurang akurat. Berdasarkan hasil dari evaluasi lain yang dilakukan, ditemukan bahwa tidak ada *missing values* , data duplikat, *invalid values* maupun nilai outlier menggunakan metode IQR dan validasi tambahan z-score pada variabel numerik data *raw* .

5.2 Effectiveness of the data wrangling


Secara umum dataset dari awal tidak memiliki *missing values* , outlier maupun duplikat. Oleh karena itu, proses *wrangling* berfungsi sebagai tahap penguatan kualitas data dimana proses ini memastikan konsistensi dan kesiapan data untuk proses analisis selanjutnya. Fokus utama data *wrangling* di Phase 1 diarahkan untuk perbaikan inkonsistensi kategorikal dan transformasi format data agar dataset siap untuk proses analisis selanjutnya.



Gambar 2. Distribusi Fitur *Frequency of Purchases* Sebelum dan Setelah Penanganan UTS


Penanganan inkonsistensi kategori tersebut dilakukan dengan menggabungkan kategori ” *Bi-weekly* ” dengan ” *Fortnightly* ” serta ” *Every 3 Months* ” dengan ” *Quarterly* ” karena memiliki makna semantik sama. Hal itu dilakukan agar hasil analisis akhir tidak ambigu dengan menghasilkan 5 kolom *Frequency of Purchases* akhir.

Selain itu, pada Phase 1 dilakukan *encoding* pada tiga variabel (*Subscription Status* , *Discount Applied* , dan *Promo Code Used*) yang berformat ” *Yes/No* ” menjadi ” *0/1* ” yang berformat numerik untuk proses *modeling* selanjutnya. Beberapa kolom yang kurang relevan dengan tujuan analisis juga di *drop* seperti *CustomerID*, *Size* dan *Color* .



Gambar 3. Distribusi Fitur Purchase Frequency Tier dan Age Group Hasil Feature Engineering Phase 1

Feature engineering pada tahap Phase 1 menghasilkan kolom *Age Group* dan *Purchase Frequency Tier*. *Age Group* mengkategorikan usia menjadi 3 kategori usia (*Adult*, *Senior*, *Young Adult*) sedangkan *Purchase Frequency Tier* mengkategorikan *spending* menjadi *High*, *Medium*, *Low*. Penambahan fitur ini bertujuan agar analisis dapat dilakukan lebih mendalam terkait *customer segmentation* dan *behaviour purchase*.



Gambar 4. Distribusi Fitur Hasil Feature Engineering Phase 2

Di Phase 2 dilakukan kembali *feature engineering* untuk memperdalam analisis yang menghasilkan kolom *Loyalty Level* dan *Customer Segmentation*. Fitur *Loyalty Level* mengkategorikan *previous purchase* ke dalam 4 kuantil menjadi *Low*, *Medium*, *High*, dan *Very High* sedangkan *Customer Segment* menggunakan persentil 0.75 dari kolom *purchase amount* untuk mengkategorikan pelanggan menjadi *high* dan *regular spender*.

5.3 Evidence from measurable indicators


SCORECARD – EVALUASI KUALITAS DATA			
Indikator	Raw	Cleaned	For Modeling
Total Missing Values	0	0	0
Duplicate Rows	0	0	0
Total Outliers (IQR)	0	0	0
Jumlah Kolom	18	17	19
Jumlah Fitur Baru	-	2	2

DELTA (Perubahan Jumlah Baris/Data):			
Total Missing	-> Cleaned vs Raw: +0	Modeling vs Cleaned: +0	
Duplicate Rows	-> Cleaned vs Raw: +0	Modeling vs Cleaned: +0	
Total Outliers	-> Cleaned vs Raw: +0	Modeling vs Cleaned: +0	

Gambar 5. Hasil Evaluasi Dataset Raw, Hasil Cleaning Phase 1 dan Phase 2

Hasil *scorecard* menunjukkan bahwa proses *wrangling* yang dilakukan dalam Phase 1 difokuskan kepada *improvement* kualitas data yakni memperbaiki inkonsistensi kategorikal dan persiapan data untuk analisis lanjutan. Dari hasil *wrangling* tersebut dapat diketahui bahwa tidak ada penambahan maupun penghapusan *row* sehingga tidak ada data yang hilang atau terduplikat saat proses *cleaning*. Setelah menghilangkan fitur yang kurang relevan dengan tujuan analisis dan *feature engineering*, jumlah kolom berkurang menjadi 17 dari sebelumnya 18 yang kemudian bertambah menjadi 19 setelah penambahan dua variabel *feature engineering* lagi di tahap di Phase 2.


Missing Values



Gambar 6. Hasil Evaluasi Missing Value Raw > Phase 1 > Phase 2

Pengecekan *missing value* dilakukan menggunakan `df.isnull()` menghasilkan total 0 *missing values* pada *raw data* (sebelum *wrangling*) dan setelah *wrangling* (hasil *cleaned Phase 1* dan final dataset).


Duplicate Rows



Gambar 7. Hasil Evaluasi Duplicate Data Raw > Phase 1 > Phase 2

Pengecekan *duplicate* dilakukan menggunakan `df.duplicated()` menghasilkan total 0 *duplicate data* di fase sebelum maupun setelah *wrangling*.

Outlier (IQR Method)



Gambar 8. Hasil Evaluasi Outlier Raw > Phase 1 > Phase 2

Deteksi outlier dilakukan pada variabel numerik menggunakan metode IQR kemudian divalidasi dengan z-score. *Lower bound* dihitung dengan rumus $Q1 - 1.5 \times IQR$ sedangkan *upper bound* dihitung dengan rumus $Q3 + 1.5 \times IQR$. Total outlier pada fase sebelum dan setelah *wrangling* menghasilkan nilai 0 yang konsisten.

Konsistensi Kategori

```
Kolom: Frequency of Purchases
[Raw] 7 kategori = ['Annually', 'Bi-Weekly', 'Every 3 Months', 'Fortnightly', 'Monthly', 'Quarterly', 'Weekly']
[Cleaned (UTS)] 5 kategori = ['Annually', 'Fortnightly', 'Monthly', 'Quarterly', 'Weekly']
[Cleaned2] 5 kategori = ['Annually', 'Fortnightly', 'Monthly', 'Quarterly', 'Weekly']
```

Gambar 9. Hasil Perbandingan Kategori Freq of Purchase

Masalah yang ditemukan pada Phase 1 adalah pada jumlah kategori di kolom *Frequency of Purchases*. Dalam *raw data* jumlah kategori pada kolom ini ada 7 kategori unik karena “Bi-Weekly”/“Fortnightly” dan “Every 3 Months”/“Quarterly” masih dikelompokkan dengan cara yang berbeda-beda. Oleh karena itu, pada fase Phase 1 dilakukan *cleaning* sehingga jumlah kategori berkurang menjadi 5 kategori.

Invalid Values

Dilakukan juga pengecekan nilai yang invalid pada fitur *Age*, *Purchase Amount* dan *Review Rating* untuk memastikan nilai-nilai tersebut sesuai dengan standar logika bisnis. Validasi dilakukan dengan

menggunakan aturan usia valid di antara 15-100, *purchase amount* > 0 dan *review rating* dalam rentang 1-5. Dari hasil evaluasi tersebut tidak ditemukan nilai yang berada di luar rentang valid pada fase sebelum dan setelah *wrangling*.

Konsistensi Tipe Data

Perbandingan Tipe Data :

	Raw	Cleaned (UTS)	Cleaned2
Age	int64	int64	int64
Age Group	NaN	object	object
Category	object	object	object
Color	object	NaN	NaN
Customer ID	int64	NaN	NaN
Customer Segment	NaN	NaN	object
Discount Applied	object	int64	int64
Frequency of Purchases	object	object	object
Gender	object	object	object
Item Purchased	object	object	object
Location	object	object	object
Loyalty Level	NaN	NaN	object
Payment Method	object	object	object
Previous Purchases	int64	int64	int64
Promo Code Used	object	int64	int64
Purchase Amount (USD)	int64	int64	int64
Purchase Frequency Tier	NaN	object	object
Review Rating	float64	float64	float64
Season	object	object	object
Shipping Type	object	object	object
Size	object	NaN	NaN
Subscription Status	object	int64	int64

Gambar 10. Hasil Pengecekan Tipe Data

Kekonsistenan tipe data dievaluasi untuk memastikan tidak ada informasi yang berubah secara tidak konsisten saat data selesai *cleaning* . Perubahan tipe data yang terlihat adalah *encoding* yang dipastikan tepat benar menjadi integer karena tipe data pada kolom *Subscription Status* , *Discount Applied* , dan *Promo Code Used* sudah tidak tersimpan sebagai teks (bertipe object).


6. Advanced Pattern, Trend & Relationship Analysis

6.1 Deeper exploration: segmentation, time-based trends and subgroup comparison


Analisis agregat sederhana tidak cukup untuk menemukan pola yang tersembunyi dalam data sehingga analisis diperluas menggunakan 3 pendekatan spesifik yakni *segmented analysis*, *time-based trends*, *subgroup comparison* .

1. Analisis Segmentasi

Demographic Segmentation




Gambar 11.



Gambar 12.

Hasil segmentasi berdasarkan *gender* dan *subscription status* (Gambar 11) menghasilkan rata-rata *purchase amount* 59–60 USD yang hampir sama. Gambar 12 menunjukkan bahwa kombinasi *Age Group* dan *Purchase Frequency Tier* juga memiliki nilai rata-rata belanja yang hampir sama sehingga faktor usia dan gender tidak membedakan seberapa besar seseorang belanja per transaksi.


Geographic Segmentation



Gambar 13.

Segmentasi geografis menyebabkan selisih *purchase amount* yang cukup besar antara lokasi dengan nilai tertinggi yaitu dari Alaska (67.597 USD) dan terendah dari Connecticut (54 USD). Selisih tersebut lebih besar daripada selisih segmentasi demografis, maka dapat dikatakan bahwa segmentasi geografis lebih berpengaruh pada pola *spending* dibandingkan segmen gender atau usia.

Spending Segmentation



Gambar 14.

Pelanggan *High Spender* memiliki rata-rata *purchase amount* 90,55 USD dengan jumlah pelanggan sebanyak 978 orang. *Regular Spender* memiliki rata-rata *purchase amount* 49,46 USD dengan jumlah pelanggan yang lebih besar (2.922 orang). Perbedaan ini terlihat jelas pada grafik perbandingan yang menunjukkan bahwa segmen kecil (*high spender*) memiliki peluang menjadi target pasar prioritas untuk program retensi.

2. Time-Based trends

Seasonal Purchase Trend




Gambar 15.



Gambar 16.

Gambar 16 menunjukkan tren *purchase amount* yang bergerak dari Spring (58.738 USD) ke Summer (58.405 USD) lalu Fall (61.557 USD) kemudian turun di Winter (60.357 USD). Tren ini membentuk pola yang berpuncak di Fall dan lembah di musim yang lebih hangat. Temuan ini menunjukkan bahwa musim yang lebih dingin cenderung mendorong transaksi lebih besar. Gambar 15 memperkuat temuan ini dari sisi volume dengan musim *winter* pada kategori *Clothing* mencatat 448 transaksi. Uji Kruskal-Wallis k dengan $H = 11,38$, $p = 0,0098 < 0,05$ juga mengkonfirmasi bahwa *season* merupakan kategori yang berpengaruh terhadap *purchase amount*. Namun, efeknya sangat kecil ($\eta^2 = 0,0029$) yang berarti musim hanya menjelaskan 0,29% dari variasi yang ada.

Seasonal Category Performance




Gambar 17.

Gambar 17 menunjukkan bahwa tren musiman tidak seragam di semua kategori dimana *footwear* mencapai puncaknya di *fall* (63.7 USD) tapi turun di *spring* (58.6 USD). Selain itu, dapat dilihat bahwa *accessories* juga mengalami fluktuasi tetapi puncaknya tersebar di *fall* dan *summer*; tidak terkonsentrasi di satu musim seperti *Footwear*. Temuan itu menunjukkan bahwa *seasonal marketing* perlu dibuat berbeda untuk tiap kategori produk.

3. Subgroup Comparison

Subscription vs Non-Subscription



Gambar 18.



Gambar 19.

Perbandingan boxplot kelompok *subscription* menghasilkan temuan yang *counterintuitive* dimana pelanggan yang *subscribe* memiliki rata-rata belanja 59.49 USD yang lebih sedikit dibandingkan *non-subscriber* (59.87 USD). Namun perbedaan ini tidak terlalu besar sehingga ini menunjukkan bahwa *subscription status* tidak menaikkan nilai belanja seseorang. Gambar 18 menambahkan informasi bahwa jumlah *subscriber* jauh lebih sedikit (1.053 pelanggan) dibanding *non-subscriber* (2.847 pelanggan) dan distribusi *frequency tier* memiliki pola yang sama dengan kategori *Low* dan *High* yang mendominasi. Ini menunjukkan bahwa *subscriber* tidak selalu berbelanja lebih banyak dari *non-subscriber*, yang mengindikasikan bahwa program *subscription* belum bisa meningkatkan nilai transaksi *subscriber*.


Loyalty Level SubGroup



Gambar 20.

Pengujian antara *category loyalty level* juga dilakukan untuk memeriksa kenaikan nilai transaksi berdasarkan loyalitas. Nilai rata-rata *purchase amount* untuk *category* tersebut memiliki perbedaan yang relatif kecil (~1 USD) dengan median sebesar 59-60 USD. Ini berarti loyalitas tidak memiliki korelasi langsung dengan nilai transaksi *customer*.

Operational Variable Subgroup



Gambar 21.

Gambar 22.

Perbandingan antara metode pembayaran dan *shipping type* dilakukan untuk mengetahui apakah pemilihan cara bayar berkorelasi dengan besar *spending*. Gambar 22 menunjukkan bahwa distribusi *purchase amount* per metode pembayaran relatif seragam. Di sisi lain, perbandingan antara tipe pengiriman juga menghasilkan distribusi *purchase amount* seragam antar *shipping type*. Berdasarkan temuan ini, variabel operasional seperti cara bayar dan pilihan pengiriman tidak berpengaruh terhadap *spending behavior* pelanggan.

Promo and Discount




Gambar 23.



Gambar 24.

Gambar 23 menunjukkan hasil perbandingan distribusi *Non-discount* (rata-rata 60.13 USD, 2.223 transaksi) dan *Discount* (rata-rata 59.28 USD, 1.677 transaksi) dengan median keduanya sama ~ 60 USD. Temuan ini menunjukkan bahwa diskon tidak menaikkan nilai belanja yang berarti program diskon saat ini berpotensi hanya sebagai penarik partisipasi. Temuan pada gambar 24 konsisten dengan temuan diskon, dimana penggunaan *promo code* tidak memiliki perbedaan yang signifikan. Selain itu, korelasi discount dan promo code hampir sempurna ($Cramér's V = 0,9995$) sehingga analisis keduanya tidak dilakukan secara terpisah agar tidak menimbulkan multikolinearitas.


Discount and Frequency Tier Subgroup




Gambar 25.

Perbandingan *discount* dengan *purchase frequency tier* dilakukan untuk mengetahui dampak pemberian diskon pada komposisi *purchase frequency tier* pelanggan. Dari gambar terlihat bahwa pelanggan tanpa menggunakan diskon justru belanja lebih banyak dengan pola distribusi *tier* yang mirip antara 2 kelompok. Hal ini menunjukkan bahwa untuk saat ini diskon masih berpotensi tidak memberikan dampak yang signifikan pada nominal pembelian.

6.2 Most influential variables



Gambar 26.



Gambar 27.

Berdasarkan Gambar 26, tidak ada variabel yang berkorelasi kuat dengan *Purchase Amount (USD)* sehingga analisis diperluas ke *subscription status* dengan mengkombinasikan analisis EDA serta

feature importance model. Berikut adalah variabel-variabel yang paling berpengaruh berdasarkan kombinasi tersebut:

Discount Applied

Variabel ini merupakan prediktor terkuat dalam menentukan status keanggotaan pelanggan dengan korelasi 0,7. Di gambar 27, *feature importance* model Logistic Regression variabel ini juga mencatat bobot koefisien tertinggi.

Gender

Berdasarkan seluruh variabel dalam analisis demografi, *gender* merupakan satu-satunya variabel yang memiliki hubungan kuat terhadap keputusan berlangganan pelanggan. Hasil ini dibuktikan dari hasil uji Cramer's $V = 0.42$ yang menunjukkan bahwa jenis kelamin memiliki hubungan moderat dengan keputusan pelanggan untuk *subscribe*.

Customer Segment

Variabel ini adalah pembeda terkuat dalam dataset yang jauh melewati perbedaan yang dihasilkan oleh variabel demografis lain sehingga variabel ini menjadi salah satu faktor yang penting.

Lokasi dan item yang dibeli

Grafik *feature importance* model LR menunjukkan bahwa fitur-fitur yang berkaitan dengan lokasi dan barang pembelian seperti *Location_Virginia* dan *Item_Purchased_Jeans* memiliki berpengaruh terhadap peluang konversi pelanggan untuk *subscribe* yang lebih besar.

6.3 Why these relationships are meaningful

Tidak ada variabel numerik tunggal yang memiliki pengaruh signifikan terhadap *purchase amount*. Oleh karena itu, fokus analisis diarahkan ke *subscription*. Model *machine learning*

(Logistic Regression) menggunakan seluruh fitur secara bersamaan berhasil memprediksi *Subscription Status* dengan akurasi 86.41% dimana ini tidak bisa dicapai oleh analisis bivariat.

1. Discount Applied

Variabel *discount applied* dan *promo code used* memiliki hubungan kuat yang dibuktikan dengan uji Chi-Square. Uji tersebut menunjukkan hubungan yang hampir sempurna (Cramér's $V = 0.9995$, $p < 0.0001$) yang membuktikan bahwa keduanya dapat diperlakukan sebagai 1 variabel tunggal saja. Selain itu, *discount applied* memiliki korelasi tinggi (0,7) dengan *subscription status* yang menunjukkan bahwa program diskon hampir selalu mengalir ke pelanggan berlangganan. Temuan ini penting karena berarti diskon tidak mendorong *non-subscriber* untuk berbelanja lebih besar, melainkan hanya mempertahankan pelanggan yang sudah berlangganan.

2. Gender

Uji Chi-Square Cramér's $V = 0.42$ & $p < 0,0001$ menunjukkan bahwa *gender* dan *subscription status* memiliki hubungan yang moderat. Temuan ini penting sebagai dasar strategi akuisisi karena sebagai salah satu variabel yang berpengaruh terhadap *subscription status*, jika segmen ini tidak dipertimbangkan maka kampanye berpotensi menjangkau audiens yang kurang responsif terhadap program *subscription*. Dari sisi analisis demografis, *gender* tidak membedakan *purchase amount* tapi

Chi-Square membuktikan bahwa gender membedakan keputusan berlangganan sehingga relevansinya ada di konversi langganan.

3. Customer Segment



Gambar 28.

Uji Mann-Whitney U Test menghasilkan $p < 0.0001$ dengan Cohen's $d = 3.12$, yang tergolong *effect size* besar. Uji juga melampaui threshold konvensional ($d > 0.8$) yang menunjukkan bahwa perbedaan *spending* antara *High Spender* dan *Regular Spender* bukanlah variasi acak. *Robustness check* juga menghasilkan nilai Cohen's d antara 2.85–3.45 dengan $p < 0.0001$ yang membuktikan bahwa hasil ini tidak sensitif terhadap pilihan batas pemisah. Oleh karena itu, perbedaan ini cukup stabil untuk dijadikan dasar segmentasi program bisnis yang berbeda.

4. Location and Item Purchased

Model Logistic Regression menghasilkan dua fitur dengan *importance* tertinggi, yaitu *Location_Virginia* dan *Item_Purchased_Jeans*. Kombinasi spesifik antara lokasi dan produk tertentu adalah variabel yang paling banyak membedakan *subscriber*.

7. Evaluation of Analytical Methods & Metrics

Implementation: notebooks 03 (statistical tests) and 04_subscription_prediction_modeling.ipynb (classification models).

7.1 Analytical techniques and models used

- Deskriptif Analysis

Analisis deskriptif yang dilakukan menggunakan statistik agregat yang umum seperti avg, median, std. deviation. Visualisasi boxplot digunakan untuk menganalisis distribusi data, *heatmap* untuk membandingkan rata-rata nilai pembelian antara dua variabel, serta grouped dan stacked bar chart untuk mengamati komposisi antar kelompok.


Correlation analysis Spearman dan Pearson dilakukan untuk mengevaluasi hubungan antara variabel numerik dengan *Purchase Amount*. Sebelum melakukan analisis inferensial, normalitas juga diuji menggunakan metode Shapiro-Wilk pada variabel *Purchase Amount*. Temuan menunjukkan bahwa data tidak mengikuti sebaran normal, sehingga seluruh analisis berikutnya menerapkan metode non-parametrik. Uji korelasi, Chi-Square dengan Cramér's V, serta perbandingan Kruskal-Wallis dan ANOVA diterapkan untuk mengevaluasi hubungan antara variabel numerik dan kategorikal. Uji Mann-Whitney U digunakan untuk memvalidasi segmentasi *High* dan *Regular Spender* dengan tambahan *robustness check* agar hasilnya tidak hanya tergantung pada satu metode. Metode ini digunakan untuk mengidentifikasi pola interaksi antara variabel dan memastikan bahwa pemisahan bisnis memiliki dasar statistik yang kokoh dan terpercaya sebelum diterapkan dalam pemodelan.

- Predictive Analysis

Analisis prediktif juga dibangun untuk memprediksi konversi pelanggan ke *subscriber* dengan 4 model klasifikasi dibangun pada tahap *baseline*.

	Model	Accuracy	F1-Macro	F1-Sub	Precision	Recall-Sub	AUC-ROC	CV Acc	CV F1-Mac	CV Std	Gen. Gap (Test-CV)	Composite
0	Logistic Regression	86.54	84.96	80.08	66.77	100.00	90.71	83.33	81.70	1.91	3.21	85,250
1	SVM	86.41	84.77	79.77	66.77	99.05	90.65	83.33	81.72	1.92	03.08	85,0633
2	Random Forest	84.74	82.28	75.66	66.55	87.68	90.91	82.92	80.53	2.40	1.83	82,9500
3	XGBoost	83.97	80.19	71.53	68.86	74.41	91.54	81.60	77.64	2.98	2.37	81,0867

Gambar 29. Perbandingan Hasil Metriks Evaluasi Model Baseline



Gambar 30. Confusion Matrix Keempat Model Baseline

Pemodelan baseline modeling menerapkan model Logistic Regression, SVM, Random Forest, dan XGBoost dengan parameter default dan tanpa *cross validation* untuk mendapatkan *benchmark* kinerja murni model. Keempat model dibangun menggunakan *pipeline* (ImbPipeline) yang mencakup tahap *pre processing* (OneHotEncoder untuk fitur kategorikal pada model linear, OrdinalEncoder untuk fitur kategorikal pada model berbasis pohon, StandardScaler untuk fitur numerik pada model linear) serta penerapan SMOTE untuk menangani *imbalance* kelompok *Subscriber* (73%) dan *Non-Subscriber* (27%). Salah satu dari fitur yang memiliki korelasi tinggi yaitu *Promo Code Used* dan *Discount Applied* dihapus salah satu untuk menghindari masalah multikolinieritas.

Berdasarkan tahap *baseline*, model terbaik yang ditentukan adalah Regresi Logistik karena memiliki skor F1-Macro dan Recall-Sub yang tinggi (masing-masing sebesar 84,96% dan 100%). Tahap kedua proyek ini mencakup hyperparameter tuning pada model yang telah dipilih dari tahap *baseline* menggunakan *RandomizedSearchCV* dan *Stratified 10-Fold Cross-Validation*. Parameter terbaik yang ditemukan adalah solver ‘saga’, penalti L1 (Lasso), dan nilai C sebesar 0,2991. Penalti L1 menyeleksi fitur dengan cara menghapus koefisien yang tidak relevan lalu diubah menjadi nol. Selain itu, analisis *feature importance* berhasil menemukan fitur-fitur penting seperti *Discount Applied*, *Location_Virginia*, dan *Item_Purchased_Jeans*.

7.2 Evaluation metrics

Metrik	Nilai (After Tuning)	Alasan Pemilihan
Accuracy	86.41%	Gambaran umum proporsi prediksi benar
F1-Macro	84.83%	Metrik utama yang menyeimbangkan performa dua kelas pada data imbalance
Recall-Sub	100.00%	Prioritas bisnis (tidak boleh ada calon _subscriber_ yang terlewat)


Metrik	Nilai (After Tuning)	Alasan Pemilihan
Precision	66.56%	Mengukur seberapa banyak prediksi <i>subscriber_yang benar-benar_subscriber</i>
AUC-ROC	91.40%	Mengukur kemampuan model memisahkan kelas
CV F1-Macro	81.87% ($\pm 1.94\%$)	Validasi generalisasi model pada data yang belum dilihat
Generalization Gap	2.98%	Indikator risiko overfitting
Cohen's d (A/B Testing)	3.12	Effect size untuk validasi segmentasi High vs. Regular Spender
Cramer's V	0.42 (Gender-Sub)	Mengidentifikasi ketergantungan antar variabel
Kruskal-Wallis & ANOVA	$\eta^2 = 0.0029$ untuk <i>season</i>	Menilai perbedaan nilai antar grup
Spearman dan Pearson	semua p-value tidak ada yang < 0.05	Mengukur hubungan linear/monotonik

Korelasi Pearson dan Spearman dipakai untuk melihat hubungan antar variabel numerik. Hasil menunjukkan bahwa seluruh variabel numerik memiliki nilai $p > 0,05$ sehingga tidak ditemukan hubungan linear maupun monotonik yang signifikan. Untuk variabel kategorikal, uji Cramér's V menghasilkan dua angka yang cukup berbeda dimana *Discount* dan *Promo Code* memiliki korelasi yang hampir sempurna (0,9995), sedangkan *Gender* dan *Subscription* menghasilkan 0,42. Uji Kruskal-Wallis dengan $p = 0,0098 < 0,05$ menunjukkan hubungan yang signifikan antara *season* dengan *purchase amount*. Namun, *effect size* dari Eta-Squared Kruskal-Wallis menunjukkan bahwa *season* tidak banyak berpengaruh terhadap *purchase amount* karena hasil Eta-Squared sangat kecil ($\eta^2 = 0,0029$). Hasil A/B testing menggunakan Mann-Whitney U Test (non-parametrik) menghasilkan perbedaan yang signifikan antara *High vs Regular Spender* dengan hasil Cohen's d = 3,12.

F1-Macro dipilih sebagai metrik utama dalam pemodelan karena dataset tidak seimbang, sehingga akurasi saja tidak cukup untuk menggambarkan performa model secara jujur. F1-Macro menghitung rata-rata F1-Score untuk setiap kelas tanpa memperhatikan proporsi. Dalam konteks bisnis, Recall-Sub menjadi hal yang utama karena dampak dari *False Negative* memiliki biaya yang lebih tinggi (kehilangan calon *subscriber* yang terlewat jauh lebih merugikan dibandingkan dengan prediksi positif yang keliru). AUC-ROC dan confusion matrix juga ikut digunakan untuk menilai seberapa baik model membedakan kedua kelas. Selisih Generalisasi antara akurasi tes set dan akurasi CV dipergunakan untuk mengidentifikasi adanya *overfitting*.

	Metric	Before Tuning	After Tuning	Delta
0	Accuracy	86.54	86.41	- 0.13
1	F1-Macro	84.96	84.83	- 0.13
2	F1-Sub	80.08	79.92	- 0.16
3	Precision	66.77	66.56	- 0.21
4	Recall-Sub	100.00	100.00	= 0.0
5	AUC-ROC	90.71	91.40	+0.69
6	CV Acc	83.33	83.43	+0.1
7	CV F1-Mac	81.70	81.87	+0.17
8	CV Std	1.91	1.94	+0.03
9	Gen. Gap (Test-CV)	3.21	2.98	-0.23

Gambar 31. Perbandingan Hasil Metrik Evaluasi Model Sebelum dan Sesudah Tuning



Gambar 32. Confusion Matrix Kedua Model Setelah dan Sebelum Tuning

Setelah dilakukan *Hyperparameter tuning*, beberapa metrik mengalami penurunan tipis (Accuracy turun 0,13%, F1-Macro turun 0,13%) sebagai *trade-off* yang dipilih. Penurunan ini menguntungkan karena didukung oleh peningkatan kemampuan generalisasi yang lebih bermakna. AUC-ROC meningkat 0,69%, CV F1-Macro meningkat 0,17%, dan *Generalization Gap* menyempit 0,23%. Penurunan *gen. gap* menunjukkan bahwa model *After Tuning* lebih stabil terhadap resiko *overfitting* dan dapat dengan mudah digeneralisasikan ke data baru dibanding *baseline*. Model berhasil tidak melewati satu pun calon subscriber yang ditunjukkan dengan *Recall-Subscriber* yang stabil.

7.3 Limitations

Keterbatasan utama dalam analisis deskriptif project ini adalah rendahnya *explanatory power* seluruh variabel terhadap *purchase amount* karena korelasi yang hampir nol di semua variabel numerik. *Effect size* yang kecil dari Kruskal-Wallis ($\eta^2 = 0.0029$ untuk *season*) menunjukkan bahwa beberapa variabel dalam dataset ini belum cukup untuk menjelaskan alasan *spending behavior* pelanggan.

Keterbatasan kedua adalah tidak adanya dimensi waktu secara eksplisit yang menyebabkan analisis *seasonal* dilakukan hanya berdasarkan label musim. Hal ini membatasi analisis *time-based* dan tidak merepresentasikan tren yang sesungguhnya.

Keterbatasan ketiga adalah dataset yang digunakan kemungkinan merupakan data sintesis yang terlihat dari distribusi *purchase amount* yang terlalu seragam dan korelasi antar variabel yang sangat lemah. Korelasi yang lemah menyebabkan model yang dilatih menjadi kurang efektif dalam melakukan generalisasi ketika dihadapkan data transaksi nyata yang lebih kompleks dan banyak noise.

Keterbatasan keempat adalah dari sisi model mengenai penerapan *label encoding* pada kolom kategori. Kolom *Item Purchased* dan *Location* yang diproses dengan *Ordinal Encoding* berarti secara tidak langsung menunjukkan adanya urutan ordinal yang sebenarnya tidak ada. Penggunaan *One-Hot Encoding* secara teknis lebih akurat tetapi berpotensi memicu *curse of dimensionality* pada dataset sehingga pilihan *trade-off* ini diambil.

8. Dashboard & Visual Communication Design


Implementation: *dashboards/phase2_executive_dashboard.twbx* (4 dashboards, 29 worksheets).

8.1 Time-series and trend visualization

Design of the seasonal trend chart

Dataset yang digunakan dalam *project* ini tidak dilengkapi fitur tanggal transaksi yang granular (tanggal atau jam). Data waktu yang tersedia hanya dimensi musim (*Spring, Summer, Winter, Fall*) sehingga visualisasi *time series* yang digunakan adalah *seasonal trend analysis* untuk melihat perubahan perilaku belanja sepanjang siklus musim. Walaupun tidak menggunakan *date granularity* , *Season* tetap merepresentasikan *time series* yang bersifat *cyclic* (*Spring* → *Summer* → *Fall* → *Winter* → kembali ke *Spring*), sehingga dapat digunakan untuk menganalisis perubahan pola pembelian pelanggan berdasarkan musim.

Visualisasi *time series* yang digunakan ditunjukkan dalam *dashboard* melalui grafik *Avg Purchase by Season* berupa *line chart*. *Line chart* ini memiliki sumbu x berupa *Season* dan sumbu y rata-rata purchase amount. *Line chart* ini juga membandingkan rata-rata belanja pelanggan dengan *promo* dan *no promo* sekaligus tiap musim.



Gambar 1. Grafik Avg Purchase by Season dalam Dashboard Executive Summary

Line chart dipilih untuk merepresentasikan data yang memiliki urutan waktu karena mempermudah observasi perubahan data sepanjang periode musim serta memungkinkan perbandingan performa antara rata-rata nilai transaksi dengan promosi dan tanpa promosi secara berdampingan dalam satu tampilan yang rapi dan sederhana (tidak *cluttered*).

Dari grafik terlihat bahwa keduanya membentuk pola yang berbeda. Garis Promo menunjukkan pola yang cukup fluktuatif sedangkan No Promo justru bergerak lebih stabil dengan kenaikan bertahap. Grafik ini menunjukkan bahwa *Fall* menjadi *peak spending season* untuk kedua segmen Promo dan No Promo, sedangkan *Summer* menjadi periode

dimana penggunaan promo justru berhubungan dengan nilai *purchase amount* yang lebih rendah.

Visualisasi ini memberikan gambaran perilaku pembelian musiman serta efektivitas penggunaan kode promosi. Melalui perbandingan pola ini, manajemen dapat mengevaluasi efektivitas strategi promosi dalam meningkatkan nilai transaksi.

Key design decisions

Time granularity yang dipilih adalah musim dengan 4 kategori (*Spring, Summer, Fall, Winter*) karena dataset tidak mengandung *time granularity* yang lebih halus. Oleh karena itu, analisis perubahan perilaku belanja pelanggan dilakukan menggunakan perbandingan musiman sesuai dengan

karakteristik data yang tersedia. Selain itu, granularitas musim juga lebih sering digunakan karena biasanya strategi promosi dan *stock* direncanakan per musim. Level *time granularity* yang dipilih sudah sesuai dengan tujuan analisis yang ingin mengetahui ada tidaknya perubahan rata-rata *purchase amount* pada setiap musim.

Sumbu x dalam visualisasi ini menggunakan *discrete time axes* dengan urutan tetap (*Spring, Summer, Fall, Winter*) yang tidak merepresentasikan urutan waktu kontinu. Penempatan variabel diskrit secara berurutan ini dipertahankan agar pola perubahan antar musim terbaca secara logis. Penggunaan garis antar titik hanya sebagai *visual aid* untuk membantu memperjelas arah perubahan (*trend direction*) rata-rata belanja antar musim tanpa mengindikasikan adanya nilai di antara tiap musim.

Data rata-rata *purchase amount* tiap musim yang ditampilkan tidak melalui proses *smoothing* . *Smoothing* tidak dilakukan karena jumlah data hanya 4 titik sehingga jika menghaluskan data akan menghilangkan informasi yang mengakibatkan garis yang dihasilkan menjadi estimasi yang tidak valid. Agregasi yang dilakukan adalah *average* dari *purchase amount* untuk tiap musim agar pembaca dapat memahami tingkat pengeluaran per transaksi sehingga meski volume transaksi berbeda perbandingan antar musim bisa tetap adil. Agregasi *average* dipilih dibanding *sum* karena tujuan analisisnya adalah membandingkan perilaku belanja per transaksi, bukan total volume transaksi.

Penggunaan anotasi label nilai pada setiap titik juga digunakan untuk memudahkan pembaca melihat nilai tiap musim dengan akurat. Label ini juga mengurangi kesalahan baca karena pembaca tidak perlu mengira-ngira posisi data di sumbu y yang menambah beban kognitif.

Potential misinterpretations

Pembaca bisa salah interpretasi jika menganggap total nilai transaksi yang tertinggi di antara musim-musim sebagai indikator performa yang lebih baik. Peningkatan nilai total tersebut belum tentu mencerminkan nilai transaksi per pelanggan yang lebih besar (misalnya dipengaruhi volume transaksi di musim itu). Oleh karena itu, evaluasi bisa kurang akurat jika tidak ada pemisahan antara nilai rata-rata dan total volume. Untuk mengatasi hal tersebut dalam visualisasi ini menggunakan agregasi *Average* dibandingkan *sum* . Melalui strategi ini

pola pembelian antar musim dapat dibandingkan secara objektif, tidak dipengaruhi perbedaan jumlah transaksi di setiap musim.


Resiko lain adalah adanya kesalahan interpretasi bahwa *line chart* menggambarkan tren kontinu sepanjang musim. Hal ini bisa menyebabkan pembaca mencoba menebak nilai di antara titik data yang sebenarnya tidak ada datanya. Oleh karena itu, label sumbu musim sebagai sumbu x diurutkan agar pembaca memahami bahwa titik-titik tersebut terpisah dan garis antar titik hanya sebagai *visual aid* agar pembaca mudah mengenali pola trennya. Selain itu, penambahan *data label* pada setiap titik juga meringankan beban kognitif pembaca dengan memberikan informasi nilai secara eksplisit.

Selain itu, sumbu y pada grafik dimulai dari 52 bukan 0. Desain ini sengaja dipertahankan agar perbedaan antar musim terlihat jelas seperti penurunan di *Summer* dan puncak di *Fall* yang perbedaannya hanya ~5 USD. Hal ini berisiko pembaca akan mengira perbedaan antar musim cukup dramatis. Oleh karena itu, mitigasi yang dilakukan adalah menampilkan anotasi label angka aktual di setiap titik data serta menampilkan KPI card (59.76 untuk *avg purchase* dan status '*Stable*'). Penambahan KPI memberikan gambaran besar stabilitas bisnis secara keseluruhan sehingga pembaca tidak menganggap perubahan kecil tersebut berdampak besar pada performa bisnis.

Visualisasi juga menggunakan dua garis *trend* berdampingan dengan warna kontras yang mewakili transaksi dengan *Promo* dan tanpa *Promo* sehingga pembaca bisa mengidentifikasi pola antar 2 kategori secara langsung dalam satu visualisasi.

8.2 Composition and proportion visualization


1. Grafik Seasonal Demand by Category (100% stacked bar chart)



Gambar 2. Grafik Seasonal Demand by Category di Excecutive Summary

Grafik *100% Stacked Bar Chart* dipilih karena ingin menunjukkan perubahan proporsi *over time* tiap kategori di sepanjang musim. Dalam grafik ini *total purchase amount* dipecah menjadi proporsi per kategori produk (*Accessories*, *Clothing*, *Footwear*, *Outerwear*) dan semua bar dinormalisasi ke 100%. Melalui pendekatan ini pembaca dapat dengan mudah membandingkan proporsi tiap kategori antar musim tanpa terpengaruh perbedaan total volume transaksi per musim.

2. Grafik Discount Dependency by Category (stacked bar chart)



Gambar 3. Grafik Discount Dependency by Category di Product & Purchasing Behaviour

Grafik ini membandingkan proporsi *purchase amount* dengan diskon dan tanpa diskon untuk tiap kategori produk. Tipe *chart* ini dipilih untuk melihat seberapa besar pengaruh diskon pada masing-masing kategori terhadap pendapatan. Grafik ini menggunakan skala absolut sehingga pembaca bisa melihat nilai nyata tiap kategori dan proporsi diskon dan tanpa diskon.

3. Grafik Subscription Rate by Loyalty Level (stacked bar chart)



Gambar 4. Grafik Subscription Rate by Loyalty Level di Customer Loyalty & CRM Strategy

Visualisasi *stacked bar chart* ini menunjukkan hubungan proporsional *part to whole relationship* antara segmen pelanggan *Subscribed* dan *Non Subscriber* di setiap tingkatan loyalitas. Dari grafik terlihat bahwa proporsi *subscriber* di semua *loyalty level* hampir identik tanpa ada kenaikan yang signifikan seiring meningkatnya level loyalitas. Temuan komposisi ini menjadi bukti visual bahwa saat ini peningkatan loyalitas pelanggan tidak diikuti peningkatan konversi pelanggan ke *subscriber*.

Meskipun visualisasi nomor 2 dan 3 tidak berbasis waktu, penyajian data ini hanya sebagai pelengkap analisis komposisi proporsi sekaligus pembandingan antara visualisasi nilai absolut dan proporsi relatif yang akan dijelaskan di poin selanjutnya.

Absolute values vs. relative proportions

Kedua pendekatan *absolute values* dan *relative proportions* digunakan sesuai dengan kebutuhan analisis masing masing visualisasi. Nilai absolut digunakan untuk menampilkan

skala sebenarnya dari suatu kelompok sedangkan proporsi relatif digunakan ketika yang ingin dibandingkan adalah komposisi antar kelompok (dengan ini perbedaan total tidak akan dipengaruhi perbandingan).

Pada visualisasi *Seasonal Demand by Category* menggunakan proporsi relatif (100% *stacked*) karena tujuannya membandingkan komposisi internal antar musim. Total *purchase amount* absolut antar musim tidak digunakan karena fokus utamanya adalah membandingkan pergeseran komposisi kategori antar musim. Visualisasi ini menormalisasi semua data musim menjadi 100% sehingga visualisasi fokus menyampaikan kontribusi setiap kategori produk terhadap total pembelian di setiap musim.

Visualisasi *Subscription rate by loyalty level* dan *Discount Dependency by Category* menggunakan *absolute values* supaya panjang batang langsung merepresentasikan nilai asli total jumlah pelanggan dan efek nyata diskon terhadap *total purchase amount*. Pembaca dapat langsung membandingkan proporsi dengan mudah karena memberikan informasi nyata masing-masing kelompok.

Nilai absolut dan relatif menjelaskan data dari perspektif yang berbeda. Jika jenis visualisasi tidak sesuai maka informasi data yang krusial bisa hilang. Keduanya menjawab pertanyaan yang berbeda sehingga pilihan jenis visualisasi harus disesuaikan dengan pertanyaan apa yang sebenarnya ingin dijawab dengan visualisasi tersebut.

Perceptual risks in composition charts

Resiko *baseline issues* bisa muncul pada *stacked bar chart 100%*, yaitu hanya segmen paling bawah yang bisa dibandingkan langsung antar kolom karena segmen itu bertumpu di garis nol yang sama.

Hal ini membuat pembaca kesulitan membandingkan segmen tengah dan atas (misalnya *Footwear dan Accessories*) secara akurat antar bar karena *baseline* visualnya berubah-ubah.

Pada grafik *Seasonal Demand by Category* , resiko ini diatasi dengan normalisasi 100% sehingga langsung menampilkan persentase porsinya. Selain itu, resiko diminimalkan dengan menggunakan urutan kategori yang sama di setiap musim dan membatasi jumlah kategori menjadi empat dengan warna-warna yang konsisten agar posisi kategori bisa langsung dipahami dengan sekali lihat. Pada grafik *Subscription Rate by Loyalty Level dan Discount Dependency by Category* resiko ini diminimalkan dengan pembatasan jumlah, penggunaan *tooltip* yang menampilkan nilai ketika di *hover* serta penggunaan warna yang konsisten di tiap tingkat loyalitas pula. Hal ini mempermudah pembaca membedakan komposisi masing-masing kelompok dengan cukup jelas.


Resiko *widening trap* terjadi jika pembaca salah mengira proporsi sebagai jumlah absolut pada grafik yang dinormalisasi ke 100%. Oleh karena itu, grafik *seasonal demand* menampilkan skala 0% hingga 100% pada sumbu y yang menunjukkan bahwa data sudah dinormalisasi (karena berakhir di 100%) sehingga pembaca bisa mengetahui bahwa angka-angka tersebut adalah relatif, bukan nilai absolut. Pada 2 grafik lainnya menampilkan

nilai absolut sehingga ini secara langsung menghindari resiko karena pembaca bisa melihat langsung “konteks ukuran” dari masing-masing kelompok.

Perceptual risk lain adalah *visual noise* (terlalu banyak warna, tekstur, atau *grid*) sehingga perhatian pembaca tidak lagi fokus pada tren utama data. Hal ini sudah dimitigasi dalam penggunaan kategori yang terbatas (tidak seperti *location* yang memiliki banyak kategori) serta pemberian label pada data agar memudahkan pembaca. Mitigasi lainnya adalah pemilihan warna yang konsisten dimana setiap kategori direpresentasikan warna yang mudah dibedakan agar pembaca tidak perlu memahami ulang warna kategori setiap berpindah grafik. Kemudahan membaca grafik juga dijaga dengan pemilihan jenis grafik yang tepat serta konsistensi urutan elemen untuk meminimalkan bias interpretasi.


8.3 Integrated dashboard design

Dashboard dirancang dalam empat halaman yang menggabungkan *multi-view dashboard* untuk mendukung *visual exploration* secara runtut. Keempat dashboard (*Executive Summary, Product & Purchasing Behaviour, Promo and Marketing Effectiveness, Customer Loyalty & CRM Strategy*) terhubung lewat navigasi tab di kanan atas dengan tab aktif selalu ditandai warna hitam. Setiap *page* dashboard memiliki fokus yang berbeda-beda mulai dari *dashboard summary* kemudian *dashboard* yang lebih detail tentang produk & *purchase behaviour* , dan efektivitas promosi & strategi retensi pelanggan.




Gambar 5. Dashboard Executive Summary

Dashboard *Executive Summary* memberikan ringkasan kinerja musiman secara keseluruhan dengan instan agar business executive dapat memahami kondisi bisnis secara cepat dan menentukan prioritas mereka sebelum lanjut metrik yang lebih detail.




Gambar 6. Dashboard Product & Purchasing Behaviour

Dashboard *product & purchasing behaviour* menampilkan beberapa perspektif analisis seperti analisis pareto untuk mengidentifikasi kategori produk mana yang memberikan kontribusi pendapatan terbesar terhadap total penjualan dan *product portfolio matrix* untuk memetakan produk berdasarkan volume penjualan dan rata-rata pendapatan per produk. Dashboard ini juga memberikan gambaran tentang efektivitas diskon di berbagai kategori produk. Kombinasi ini memungkinkan pembaca memahami perilaku belanja produk dari berbagai sudut pandang.



Gambar 7. Dashboard Promo & Marketing Effectiveness

Dashboard *Promo & Marketing Effectiveness* berfokus untuk menjelaskan pengaruh promosi terhadap perilaku belanja melalui analisis tingkat adopsi promo serta perbandingan nilai rata-rata transaksi dengan promo dan tidak. Dashboard ini membantu pembaca mengevaluasi efektivitas strategi pemasaran secara menyeluruh.



Gambar 8. Dashboard Customer Loyalty & CRM Strategy

Dashboard *Customer Loyalty & CRM Strategy* mengevaluasi loyalitas pelanggan melalui distribusi tingkat loyalitas, riwayat pembelian, serta subscription rate yang bertujuan untuk memahami profil pelanggan. Dashboard ini membantu pembaca memahami lebih dalam hubungan antara loyalitas pelanggan dan perilaku pembelian.

Analytical and visual flow

1. View Hierarchy

Tiap halaman memiliki hierarki yang sama yakni baris filter paling atas, KPI card sebagai ringkasan utama kemudian *chart-chart* detail. Urutan ini dibuat mengikuti prinsip 'overview first, detail on demand' yang membantu pembaca memahami informasi secara bertahap mulai dari umum hingga yang lebih detail.

Elemen yang pertama kali terlihat pembaca adalah judul dashboard yang merepresentasikan fokus analisis setiap dashboard. Tombol navigasi di kanan atas dibuat untuk memudahkan pembaca mengakses perpindahan antar halaman dashboard tanpa harus keluar dulu dari dashboard. Menu filter diletakkan di bawah judul di bagian atas sehingga pengguna dapat melakukan eksplorasi data untuk menghasilkan informasi spesifik yang diinginkan. Kemudian perhatian pembaca terletak pada deretan KPI sebagai ringkasan metrik utama. Kemudian terakhir menampilkan visualisasi analitis yang berada pada bagian bawah dashboard untuk menjelaskan hubungan antar variabel secara mendalam melalui berbagai jenis grafik seperti *line chart*, *stacked bar chart*, *heatmap* dan lainnya.

Dengan alur logis dari gambaran umum → filter → *key metrics* (KPI) → analisis variabel yang mendalam, pembaca dapat melakukan eksplorasi data secara bertahap tanpa merasa terbebani oleh kompleksitas informasi.

2. Layout Structure

Tiap dashboard menggunakan grid dua atau tiga kolom untuk chart agar mata bisa membaca dari kiri ke kanan secara natural. Semua elemen dalam dashboard disusun menggunakan layout yang konsisten sehingga pembaca dapat mengenali pola dengan cepat dan mengurangi waktu pencarian informasi. Visualisasi yang memiliki fungsi sebagai analisis utama diberikan

ukuran yang lebih besar, sedangkan visual pendukung ditempatkan pada sisi kanan atau bawah dengan ukuran yang lebih kecil.

Sebagai contoh di *Product & Purchasing Behaviour* menempatkan pareto chart di sisi kiri dan sisi kanan berisi *Product Portfolio Matrix* dan *Discount Dependency* yang saling berhubungan. Layout ini menciptakan alur baca dari ‘produk apa yang paling laku’ ke ‘bagaimana posisi produk itu di matriks revenue-volume’ ke ‘seberapa bergantung kategori itu pada diskon’.

3. Coordination between views (filters, highlights, or interactions).

Koordinasi antar- view pada dashboard menggunakan tombol navigasi dan *interactive filter*. Untuk memperkaya analisis, setiap dashboard menyediakan filter *dropdown* yang relevan. Ketika pembaca mengubah filter maka seluruh visualisasi yang menggunakan filter tersebut akan diperbarui secara otomatis sehingga pembaca tidak perlu berpindah dashboard untuk melakukan eksplorasi mandiri. Desain dashboard ini memungkinkan pembaca melakukan interaksi langsung dengan filter untuk eksplorasi adhoc, mengklik *button* navigasi untuk memudahkan perpindahan dashboard serta melakukan hover untuk melihat detail data pada grafik. Penggunaan *interactive filter* membuat dashboard responsif terhadap eksplorasi yang dilakukan pembaca.

Navigating the data without cognitive overload

Dalam mendesain dashboard ini, pengurangan beban kognitif pembaca diprioritaskan dengan mengelompokkan data kompleks ke dalam empat dashboard dengan filter yang relevan dengan topik yang dibahas di tiap dashboard sehingga pengguna dapat fokus pada satu topik dulu tanpa terdistraksi semua informasi yang lain. Setiap halaman juga dibatasi maksimal 2-3 visual utama untuk menjaga kejelasan informasi. Dashboard ini juga menerapkan layout yang seragam di seluruh halaman (posisi di atas untuk KPI card & button navigasi serta chart detail di bawah) yang memungkinkan pembaca cepat memahami pola tanpa perlu mempelajari layout lagi saat berpindah dashboard.

Setiap elemen visual dipilih sesuai dengan tujuan analisis untuk mengurangi resiko misinterpretasi. Grafik *line chart* digunakan untuk menjelaskan tren antar musim, *bar chart* untuk perbandingan kategori, dan *scatter plot* untuk melihat hubungan antar volume penjualan dan rata-rata *purchase amount* produk. Semua grafik didesain dengan judul, label, dan legenda yang jelas, serta penggunaan semantik warna yang konsisten di semua halaman. Konsistensi ini dijaga agar pembaca dapat segera mengenali makna warna tersebut saat berpindah grafik.

Dashboard ini juga didesain menggunakan pemilihan warna yang netral seperti latar belakang abu-abu muda dan *card* berlatar belakang putih sehingga data utama bisa lebih ditonjolkan. Kompleksitas data yang tinggi (*scatter plot*) diatasi dengan mengelompokkan warna berdasarkan kategori agar pengguna dapat memfilter informasi penting secara langsung. Oleh karena itu, dashboard ini sudah disusun untuk memudahkan eksplorasi serta meminimalkan beban kognitif maupun misinterpretasi dari sisi pembaca.

8.4 Storytelling, audience fit and design defense

Intended audience and decision context

Dashboard ini ditujukan untuk pengguna non-teknis yang berperan dalam pengambilan keputusan bisnis seperti dewan direksi, *management consultant*, *marketing manager* dan *CRM manager* yang kebutuhan utamanya adalah *insight* yang langsung bisa ditindaklanjuti, bukan eksplorasi data yang terbuka luas. Pengguna sekunder contohnya *business intelligence analyst* yang akan menggunakan dashboard ini untuk menyusun laporan musiman atau menelusuri *root* dari permasalahan. Pengguna tersebut butuh dashboard yang bisa menjelaskan faktor-faktor yang mempengaruhi performa bisnis untuk menelusuri *root* permasalahan dari berbagai sudut pandang. Oleh karena itu, dashboard ini

disusun dengan menampilkan ringkasan metrik utama dulu kemudian diintegrasikan dengan dashboard yang lebih spesifik seperti analisis produk, efektivitas promosi, dan *customer retention management* yang saling berkaitan.

Konteks keputusan yang diambil terkait strategi bisnis, seperti strategi alokasi anggaran kampanye lintas musim (sebaiknya *invest* lebih banyak di musim apa), prioritas kategori produk mana yang perlu dijadikan fokus promosi, apakah strategi diskon perlu dilanjutkan atau tidak dan apakah diskon ini menghasilkan *return* atau justru mensubsidi pembelian yang memang sudah akan terjadi tanpa perlu diskon, serta strategi lain seperti perancangan program berlangganan untuk memastikan menjangkau audiens tepat.

Dashboard ini ditujukan untuk dua kelompok pengguna sekaligus sehingga *executive summary* dengan KPI card serta grafik tingkat atas ditujukan untuk eksekutif, sementara dashboard yang lebih spesifik dengan grafik detail ditujukan untuk level analis. Dengan struktur data yang jelas, dashboard ini bisa digunakan sebagai alat bantu pengambilan keputusan yang membantu mereka mengambil keputusan bisnis.

One clear visual message

Klaim utama : Strategi promosi saat ini belum mendorong return peningkatan nilai belanja pelanggan yang signifikan

Klaim tersebut didukung menggunakan beberapa visualisasi seperti KPI yang menunjukkan rata-rata pengeluaran pelanggan lebih tinggi tanpa promosi (60,13 USD) dibandingkan dengan promosi (59,28 USD) dengan selisih kecil meskipun adopsi promo sudah cukup tinggi (43%). Selain itu, tidak ada segmen pelanggan yang menunjukkan peningkatan berarti akibat penggunaan diskon karena nilainya hampir sama yang didukung oleh visualisasi grafik segment comparison. Grafik *Avg Purchase by Season* juga mendukung temuan ini dimana grafik menunjukkan garis No Promo konsisten berada di atas garis Promo pada keempat musim. Selain itu, *Heatmap Adoption by Segment & Season* menunjukkan bahwa tingkat adopsi promo segmen *High Spender* rata-rata lebih rendah (38-45%) dibanding *Regular Spender* (41-46%) yang mengonfirmasi bahwa promosi cenderung lebih banyak diadopsi oleh pelanggan bernilai lebih rendah. Semua visualisasi tersebut memberikan bukti

yang saling mendukung temuan bahwa strategi promosi saat ini belum memberikan return yang setimpal karena tingginya penggunaan promo tidak diikuti peningkatan rata-rata *purchase amount* tiap *customer segment*.

Defending the design decisions

1. Underlying Assumptions

- Desain dalam dashboard ini berlandaskan beberapa asumsi yang berkaitan dengan karakteristik pengguna dashboard dan struktur data yang digunakan. Desain ini menggunakan asumsi bahwa audiens memiliki lebih nyaman dengan angka ringkas dan warna yang netral dibanding visual yang terlalu teknis (contoh : *box plot*). Diasumsikan juga audiens akan membaca dashboard dalam waktu singkat, sehingga KPI card diletakkan di bagian atas tiap halaman untuk menyampaikan angka penting lebih dulu. Asumsi ketiga adalah pengguna diasumsikan sudah paham istilah dan metrik bisnis dasar sehingga tidak perlu adanya penjelasan definisi tiap metrik. Asumsi keempat adalah variabel *season* dianggap cukup mewakili dimensi waktu karena di dataset ini tidak tersedia level tanggal detail sehingga variabel *season* ini menjadi representasi sementara untuk melihat pola pembelian sepanjang

tahun. Asumsi ini valid untuk analisis ritel *fashion* di mana strategi bisnis biasanya dilakukan per musim.

2. Trade-off design

Ada beberapa *trade-off* desain yang sengaja diambil demi menjaga kejelasan info yang ingin disampaikan. Jumlah *chart* dalam setiap dashboard sengaja dibatasi 2-3 *chart* agar tidak menimbulkan *cognitive overload*. *Trade off* ini menghasilkan konsekuensi dimana kelengkapan statistik jadi berkurang. Selain itu, pemecahan fokus analisis menjadi empat dashboard memberikan keuntungan bagi pembaca agar bisa fokus setiap halaman sehingga juga mengurangi *cognitive overload*. Pemilihan ini memiliki *trade off* dimana pembaca harus berpindah dashboard untuk melihat gambaran bisnis secara menyeluruh dari sisi *product*, *promo* dan *customer retention*. Filter juga dibuat spesifik setiap halaman agar eksplorasi tetap teratur. Namun, hal ini memiliki konsekuensi karena membatasi eksplorasi data pengguna. Sebagai solusi, penggunaan *global filter* bisa diterapkan di masa depan agar eksplorasi data bisa lebih fleksibel.

3. Why the chosen design is appropriate and defensible for the audience Desain sudah sesuai dan cocok untuk target pengguna eksekutif karena keempat dashboard disusunurut mengikuti alur logis dari *summary* ke detail dimana ini sudah umum dipakai dalam bisnis yang mendukung pemahaman informasi secara bertahap sehingga pengguna tidak butuh pelatihan tambahan untuk memahaminya. Selain itu, setiap klaim yang muncul seperti *peak season*, *adoption rate*, atau *avg previous purchases* selalu bisa di *traceback* lewat *KPI card* atau *chart* spesifik di dashboard sehingga tidak ada *insight* yang berdiri sendiri tanpa bukti visual. Ketiga, pemberian filter interaktif di tiap dashboard memberikan peluang bagi pengguna untuk menggali lebih dalam secara lebih spesifik. Selain itu, penggunaan warna yang konsisten di

setiap *chart* dan layout yang seragam dipilih agar memastikan pengalaman pengguna tetap optimal sepanjang proses analisis.

Desain ini juga bisa dipertanggungjawabkan untuk target pengguna bisnis karena *chart* yang dipakai sederhana yang tidak butuh pemahaman statistik khusus seperti histogram. Dashboard ini mengutamakan kejelasan dan kemudahan pemahaman terhadap data dibandingkan eksplorasi data yang mendalam. Hal ini sesuai dengan konteks pengambilan keputusan cepat yang dihadapi target pengguna bisnis.

Published dashboard (Tableau Public):
<https://public.tableau.com/app/profile/nabila.mukhbata/viz/CustomerShoppingBehaviorAnalysisDashboard/ExecutiveSummary?publish=yes&showOnboarding=true>

9. Recommendations

Recommendation 1 — Strategi Akselerasi Konversi Pelanggan melalui Segmentasi Berbasis Gender

Proposal

Berdasarkan evaluasi statistik (Cramér's $V = 0,417$, $p < 0,0001$) yang menunjukkan adanya hubungan signifikan antara gender dan *subscription status*, ditemukan peluang besar untuk meningkatkan basis *subscriber* melalui segmen *female* yang saat ini belum terkonversi dengan baik. Fakta bahwa terdapat

1.248 pelanggan *female* seluruhnya berstatus *non-subscriber* dibandingkan dengan 39,7% pelanggan *male* yang sudah berlangganan, menegaskan adanya kesenjangan pasar yang signifikan. Hal ini menunjukkan pertumbuhan *subscriber* yang belum terkonversi dengan baik sehingga bisa dijadikan titik masuk strategi akuisisi.

Variabel diskon bisa menjadi instrumen konversi yang didukung temuan bahwa *Discount Applied* merupakan prediktor paling kuat dalam model *Logistic Regression* dan memiliki korelasi sebesar 0,70 dengan *subscription status*. Berdasarkan temuan ini, perusahaan dapat membuat strategi kampanye akuisisi yang menargetkan kelompok *female* melalui program *subscription* berbasis insentif diskon. Dapat dilakukan penekanan pada jenis produk yang paling sering dibeli oleh kelompok ini seperti *accessories* dan *clothing*. Untuk meningkatkan efisiensi, model prediktif dapat diterapkan ke dalam sistem CRM untuk mengidentifikasi konsumen *female* yang pola belanjanya paling mirip dengan *subscriber* sehingga strategi marketing bisa lebih tepat sasaran.

How it supports decision making

Rekomendasi ini bertujuan untuk menghindari kampanye yang bersifat *one size fits all* karena kampanye massal akan cenderung mengirimkan penawaran yang sama kepada semua orang. Ini mengakibatkan anggaran habis untuk menjangkau pelanggan yang kemungkinan besar tidak tertarik. Kombinasi antara data kesenjangan konversi gender dan *feature importance* model memberi argumen yang bisa diukur untuk menentukan kemana anggaran promosi sebaiknya dialokasikan, insentif apa yang dipakai (diskon), dan produk mana yang jadi fokus (*Accessories* dan *Clothing*).

Bagi manajemen keuangan, model prediksi bisa diintegrasikan ke CRM sehingga promosi tidak perlu lagi disebar ke semua orang. Dengan menyasarkan pelanggan yang memang punya peluang tinggi untuk konversi akan membuat biaya per akuisisi *subscriber* bisa turun karena anggarannya tidak terbuang ke tempat yang salah.

Selain itu, rekomendasi ini sangat penting bagi pertumbuhan perusahaan di masa depan. Dengan mengubah 1.248 pelanggan perempuan menjadi pelanggan yang berlangganan, perusahaan tidak hanya berhasil meningkatkan jumlah pelanggan setia, tetapi juga membangun sumber pendapatan yang konsisten dan jangka panjang (*recurring revenue*). Perusahaan tidak perlu lagi mengeluarkan banyak uang untuk mendapatkan pelanggan baru, melainkan dapat memfokuskan perhatian pada optimalisasi terhadap pelanggan yang sudah ada. Segmen ini sudah ada dan memiliki ciri-ciri yang jelas, sehingga yang diperlukan hanyalah mengubah mereka menjadi pelanggan berlangganan dengan strategi yang lebih efektif.

Risks and considerations

Hubungan nyata dari hasil uji antara gender dan *subscription status* ($\text{Cramér's } V = 0,417$) ini tidak selalu mengenai sebab-akibat dimana variabel gender sendiri bisa saja bukan penyebab langsungnya. Bisa jadi ada faktor lain yang kebetulan membuat *subscription rate* pada pelanggan perempuan rendah seperti preferensi produk atau penawaran yang dari awal memang tidak dirancang untuk *female*. Jika kampanye dibangun semata atas asumsi gender tanpa investigasi lebih lanjut, ada risiko menimbulkan persepsi negatif di sebagian pelanggan.

Selain itu, tingkat *precision* model yang berada di angka 66,56% menuntut optimasi *threshold* prediksi sebelum sistem dioperasikan secara penuh. Penyesuaian ini akan diselaraskan dengan rasio biaya promosi aktual, sehingga efisiensi sumber daya akuisisi dapat terjaga dan risiko pengeluaran yang tidak efektif dapat diminimalisir.

Jika diskon sebagai instrumen akuisisi ternyata merupakan benefit dari status *subscriber*, maka variabel ini mencerminkan karakteristik subscriber yang sudah ada, bukan driver akuisisi. Oleh karena itu, rekomendasi insentif diskon sebaiknya divalidasi lebih lanjut. Sebelum anggaran besar dikeluarkan, lebih aman menggeser fokus kampanye ke relevansi konten dan manfaat konkret yang bisa dirasakan pelanggan. A/B testing di skala kecil bisa jadi langkah awal untuk memvalidasi apakah pendekatan ini benar-benar bekerja.

Recommendation 2 — Peninjauan Ulang Strategi Diskon sebagai Alat Konversi Subscriber

Proposal

Berdasarkan hasil EDA variabel diskon tidak berfungsi untuk meningkatkan *spending* yang ditunjukkan dengan korelasi mendekati 0. Di sisi lain, adanya korelasi 0.70 antara *Discount Applied* dan *Subscription Status* menunjukkan bahwa diskon justru sangat terkait dengan *Subscription Status*. Hal ini diperkuat dengan *feature importance* pada model logistic regression dimana *discount applied* adalah prediktor terkuat.

Ini berarti diskon saat ini lebih efektif sebagai alat untuk mendapatkan pelanggan baru dibandingkan untuk meningkatkan nilai transaksi. Oleh karena itu, perusahaan perlu mengevaluasi fungsi diskon supaya daripada menyebarkan diskon secara massal untuk mendorong *spending* yang terbukti tidak berhasil, sebaiknya diskon diberikan secara terencana sebagai insentif untuk mendorong *subscription* seperti diskon eksklusif pertama untuk mendorong *trial subscription* yang diikuti *loyalty reward* bagi pelanggan yang tetap berlangganan serta diskon yang terkait dengan target pembelanjaan minimum (*spend-to-unlock*) untuk mendorong *regular spender* meningkatkan nilai transaksi dan menarik minat mereka untuk berlangganan.

How it supports decision making

Untuk tim keuangan, temuan bahwa diskon tidak berpengaruh pada nominal pembelian dapat menjadi argumen yang kuat untuk mengevaluasi efektivitas pengeluaran untuk promosi yang dilakukan. Jika pemberian diskon tidak dapat meningkatkan pengeluaran, berarti sebagian dari anggaran promosi yang dialokasikan tidak memberikan return yang nyata. Mengalokasikan dana dari diskon masal ke program diskon yang lebih teratur berdasarkan konversi pelanggan berpotensi menghasilkan hasil yang lebih terukur.

Bagi tim pemasaran, perubahan fungsi diskon dari “penyumbang *spending*” menjadi “tools konversi *subscriber*” akan mempengaruhi proses merancang dan mengevaluasi *campaign marketing*. Keberhasilan program diskon tidak lagi dinilai dari peningkatan average *purchase amount* per transaction, namun dari peningkatan *conversion rate* ke *subscription*.

Risks and considerations

Risiko utama rekomendasi ini adalah potensi *reverse causality* dimana korelasi 0.70 antara diskon dan *subscription status* tidak serta merta membuktikan bahwa diskon memicu konversi, tapi bisa saja mencerminkan program yang berjalan di mana pelanggan berlangganan otomatis menerima keuntungan berupa diskon. Jika terjadi salah interpretasi maka program diskon bisa jadi tidak efektif.

Hasil EDA juga menunjukkan bahwa diskon tidak benar-benar menggerakkan nilai transaksi dengan selisih rata-rata antara pelanggan yang dapat diskon (\$59,28) dan yang tidak (\$60,13) tidak sampai satu dolar. Risiko lainnya adalah tergerusnya margin keuntungan karena analisis menunjukkan diskon

tidak menaikkan *purchase amount* sehingga setiap potongan harga yang diberikan akan langsung memotong keuntungan tanpa adanya kenaikan nominal belanja. Oleh karena itu, program baru harus membatasi persentase maksimum dan durasi aktivitas promosi secara ketat untuk menjamin biaya akuisisi (*CAC*) tidak melebihi Customer Lifetime Value (*CLV*).